Анализ временных рядов и предсказание количества поездок на неделю вперед

В этом ноутбуке данные группируется по количеству поездок за день, проводится анализ полученного временного ряда, делаются предсказания количества поездок на неделю вперед.

In [75]:

```
import scipy as sps
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
from tqdm.notebook import tqdm

from sklearn.metrics import mean_squared_error as MSE

import plotly.graph_objects as go
import plotly.express as px
import plotly.offline

from statsmodels.tsa.seasonal import seasonal_decompose
import statsmodels.api as sm
from statsmodels.tsa.stattools import kpss
import gc
#from fbprophet import Prophet

import warnings

warnings.filterwarnings('ignore')
sns.set(font_scale=1.5)
```

Загрузим данные о поездках.

In [2]:

```
trips = pd.read_csv('cycle-share-dataset/trip.csv', error_bad_lines=False,
                    parse_dates=[1, 2])
```

```
b'Skipping line 50794: expected 12 fields, saw 20\n'
```

In [3]:

```
1 trips.head()
```

Out[3]:

	trip_id	starttime	stoptime	bikeid	tripduration	from_station_name	to_station_name	from
0	431	2014-10-13 10:31:00	2014-10-13 10:48:00	SEA00298	985.935	2nd Ave & Spring St	Occidental Park / Occidental Ave S & S Washing...	
1	432	2014-10-13 10:32:00	2014-10-13 10:48:00	SEA00195	926.375	2nd Ave & Spring St	Occidental Park / Occidental Ave S & S Washing...	
2	433	2014-10-13 10:33:00	2014-10-13 10:48:00	SEA00486	883.831	2nd Ave & Spring St	Occidental Park / Occidental Ave S & S Washing...	
3	434	2014-10-13 10:34:00	2014-10-13 10:48:00	SEA00333	865.937	2nd Ave & Spring St	Occidental Park / Occidental Ave S & S Washing...	
4	435	2014-10-13 10:34:00	2014-10-13 10:49:00	SEA00202	923.923	2nd Ave & Spring St	Occidental Park / Occidental Ave S & S Washing...	

Глава 1. Анализ временных рядов

1. Кол-во поездок в зависимости от даты

Отобразим количество поездок в зависимости от даты.

Преобразуем сначала данные для удобства подсчёта.

In [12]:

```
time_data = trips[['trip_id', 'starttime', 'stoptime']].copy()

time_data['start_year'] = time_data['starttime'].dt.year
time_data['start_month'] = time_data['starttime'].dt.month
time_data['start_day'] = time_data['starttime'].dt.day
time_data['start_date'] = time_data['starttime'].dt.date
time_data['start_time'] = time_data['starttime'].dt.time
time_data['start_weekday'] = time_data['starttime'].dt.dayofweek

time_data['stop_year'] = time_data['stoptime'].dt.year
time_data['stop_month'] = time_data['stoptime'].dt.month
time_data['stop_day'] = time_data['stoptime'].dt.day
time_data['stop_date'] = time_data['stoptime'].dt.date
time_data['stop_time'] = time_data['stoptime'].dt.time
time_data['stop_weekday'] = time_data['stoptime'].dt.dayofweek

time_data.drop(columns=['starttime', 'stoptime'], inplace=True)

time_data.head()
```

Out[12]:

	trip_id	start_year	start_month	start_day	start_date	start_time	start_weekday	stop_year	s
0	431	2014	10	13	2014-10-13	10:31:00	0	2014	
1	432	2014	10	13	2014-10-13	10:32:00	0	2014	
2	433	2014	10	13	2014-10-13	10:33:00	0	2014	
3	434	2014	10	13	2014-10-13	10:34:00	0	2014	
4	435	2014	10	13	2014-10-13	10:34:00	0	2014	

In [13]:

```
trips_by_date = time_data.groupby('start_date').count()['trip_id']

trips_by_date
```

Out[13]:

```
start_date
2014-10-13    818
2014-10-14    982
2014-10-15    626
2014-10-16    790
2014-10-17    588
             ...
2016-08-27    333
2016-08-28    392
2016-08-29    369
2016-08-30    375
2016-08-31    319
Name: trip_id, Length: 689, dtype: int64
```

In [14]:

```
plt.figure(figsize=(20, 6))
sns.set_style('darkgrid')

plt.title('Зависимость количества поездок от даты')

plt.plot(trips_by_date.index, trips_by_date)
plt.xlabel('Дата начала поездки')
plt.ylabel('Количество')

plt.show()
```

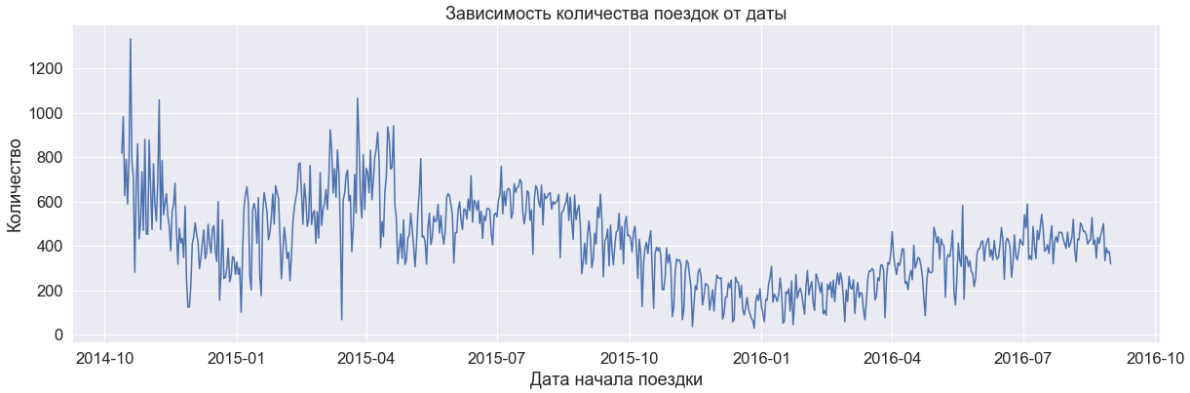

Наблюдения: видно что в зависимости от даты у кол-ва поездок меняется дисперсия. Также на многих промежутках времени явно прослеживается тренд, поэтому скорее всего ряд не стационарен

2. Стационарность

Проверим ряд на стационарность с помощью критерия KPSS.

In [15]:

```
kpss(trips_by_date)
```

Out[15]:

```
(1.5432360160081644,
 0.01,
 20,
 {'10%': 0.347, '5%': 0.463, '2.5%': 0.574, '1%': 0.739})
```

Наблюдение

Гипотеза о стационарности отверглась. Значит, имеет смысл исследовать ряд на тренд и сезонность.

3. STL-декомпозиция

Применим STL-декомпозицию к полученному временному ряду.

In [16]:

```
decomposed = seasonal_decompose(trips_by_date, freq=30)

day_decomp = seasonal_decompose(trips_by_date, freq=7)
```

In [17]:

```
plt.figure(figsize=(17, 15))

plt.subplot(411)
plt.plot(trips_by_date.index, decomposed.trend)
plt.title('Тренд')

plt.subplot(412)
plt.plot(trips_by_date.index, decomposed.seasonal)
plt.title('Месячная сезонность')

plt.subplot(413)
plt.plot(trips_by_date.index, day_decomp.seasonal)
plt.title('Недельная сезонность')

plt.subplot(414)
plt.plot(trips_by_date.index, decomposed.resid)
plt.title('Остатки')

plt.tight_layout()
```

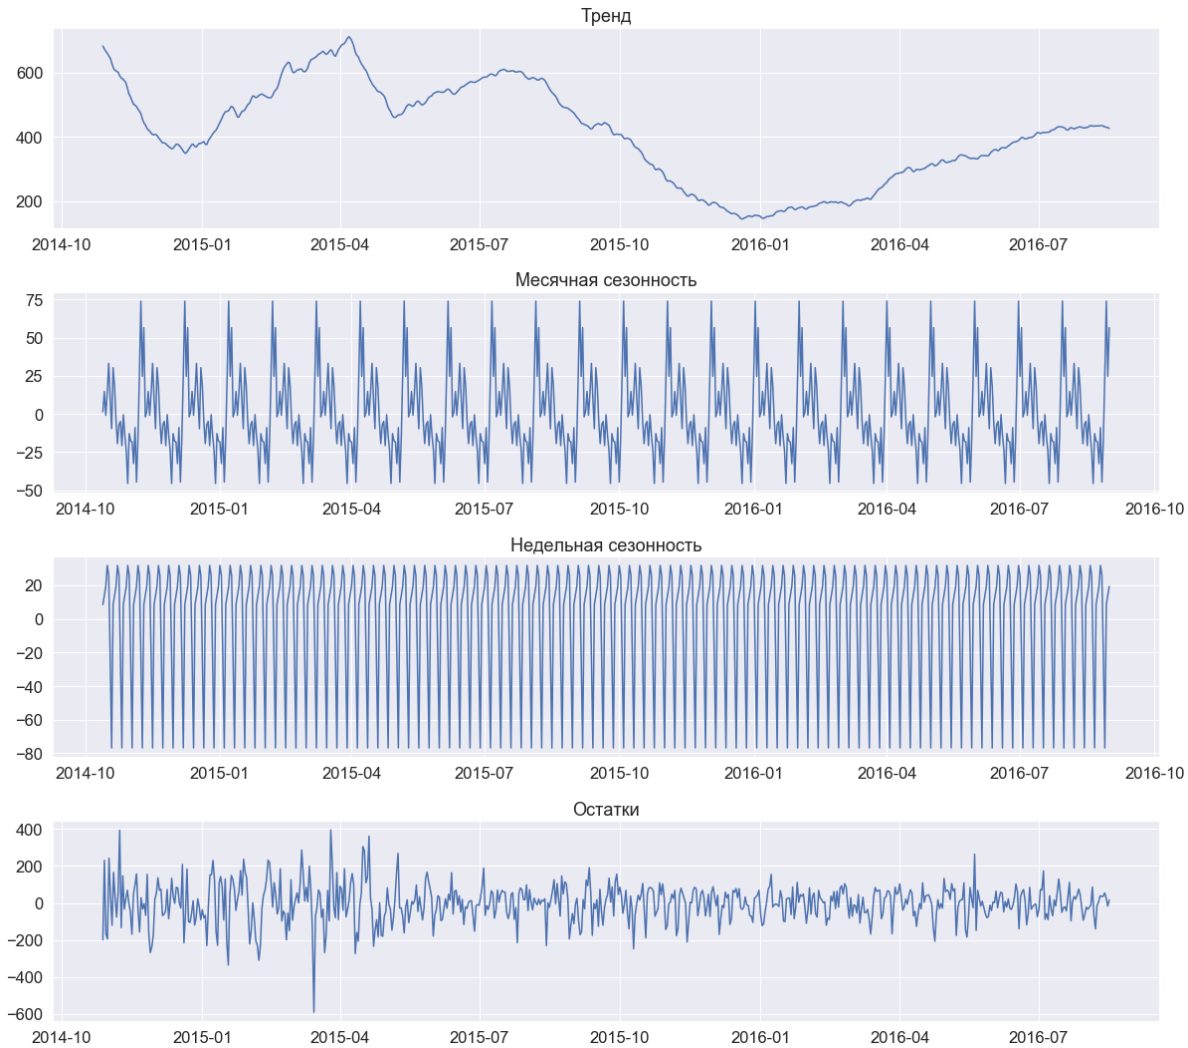

Наблюдение

На графиках отчётливо прослеживается недельная и месячная сезонность. Исследовать годовую сезоннность с помощью декомпозиции не представляется возможным, т.к. в датасете нет данных за полных два года.

4. Автокорреляция

Построим теперь графики автокорреляций для продифференцированного ряда, т.к. в данных, очевидно, наблюдается и тренд, и сезонность.

Для удаления тренда и всех сезонностей продифференцируем ряд несколько раз.

In [18]:

```
diff =  trips_by_date.values[1:] - trips_by_date.values[:-1]
month_diff = diff[30:] - diff[:-30]
week_diff = month_diff[7:] - month_diff[:-7]
```

In [19]:

```
plt.figure(figsize=(14, 7))
plt.title('Ряд после дифференциирования')
plt.plot(trips_by_date.index.values[38:], week_diff)
plt.show()
```

Наблюдение: тренд и сезонность кажется убраны, но дисперсия все равно не стабильна.

Проверим гипотезу о стационариности.

In [20]:

```
kpss(week_diff)
```

Out[20]:

```
(0.02203749101702757,
 0.1,
 20,
 {'10%': 0.347, '5%': 0.463, '2.5%': 0.574, '1%': 0.739})
```

Как видим теперь гипотеза о стационарности не отвергается

In [21]:

```
fig = plt.figure(figsize=(15, 6))

ax = fig.add_subplot(111)
fig = sm.graphics.tsa.plot_acf(week_diff, lags=150, ax=ax)
ax.set_xticks(np.arange(0, 151, 5))

plt.setp(ax.get_xticklabels(), fontsize=13)
ax.set_xlabel('lag')

plt.show()
```

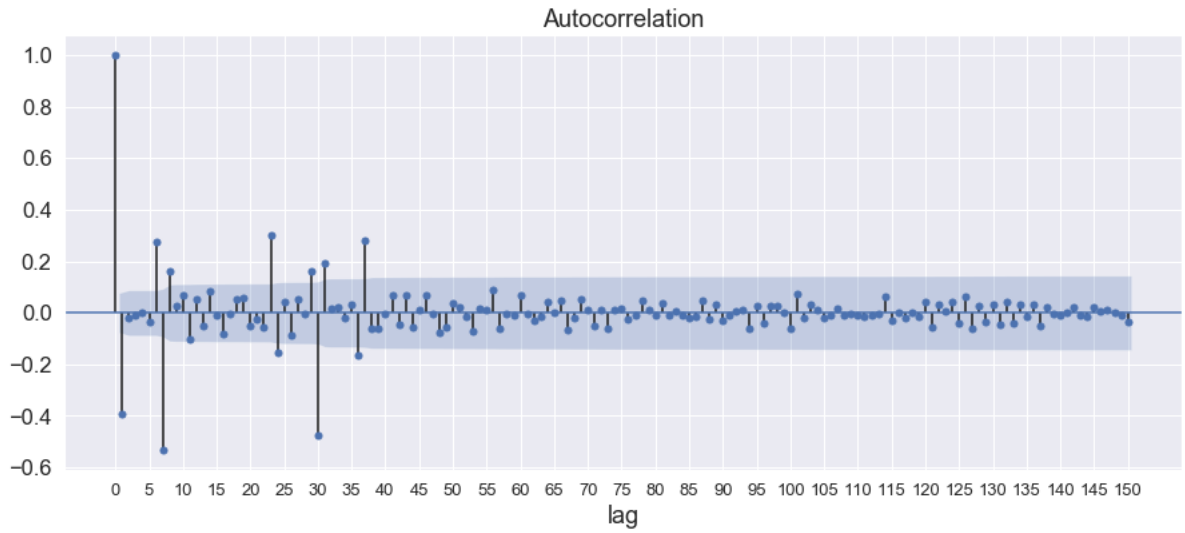

Вывод

Значимыми оказались лаги 1, 6, 7, 23, 24, 30, 36, 37. Значения 7 и 30 учитывать не стоит, т.к. дифференцирование могло "снять" не всю сезонность. Остальные результаты помогут в подборе параметров предсказательных моделей. Таких, как, например, ARIMA.

Глава 2. Предсказание поездок на неделю вперёд

0. Разбиение данных

Разобьем поездки на интервалы по 30 минут.

In [22]:

```
1 time_data.head()
```

Out[22]:

	trip_id	start_year	start_month	start_day	start_date	start_time	start_weekday	stop_year	s
0	431	2014	10	13	2014-10-13	10:31:00	0	2014	
1	432	2014	10	13	2014-10-13	10:32:00	0	2014	
2	433	2014	10	13	2014-10-13	10:33:00	0	2014	
3	434	2014	10	13	2014-10-13	10:34:00	0	2014	
4	435	2014	10	13	2014-10-13	10:34:00	0	2014	

In [23]:

```
1  def time_round(s):
2      if int(s[0]) >= 3:
3          return '30'
4      else:
5          return '00'
6
7  time_data.start_time = time_data.start_time.values.astype(str)
8  time_data['time'] = [str(day) + ' ' + s[0:3] + time_round(s[3:4]) + ':00'
9                       for s, day in zip(time_data.start_time.values, time_data.
```

In [24]:

```
1 time_data['time'] = [pd.to_datetime(s) for s in time_data.time.values]
```

In [25]:

```
1 series = time_data.groupby('time').count()['trip_id'].to_frame()
```

In [26]:

```
1 series['count'] = series.trip_id
2 series = series.drop(columns=['trip_id'])
```

In [29]:

```
1 series
```

Out[29]:

time	count
2014-10-13 10:30:00	12
2014-10-13 11:30:00	108
2014-10-13 12:00:00	42
2014-10-13 12:30:00	42
2014-10-13 13:00:00	36
...	...
2016-08-31 21:00:00	3
2016-08-31 21:30:00	2
2016-08-31 22:00:00	4
2016-08-31 22:30:00	4
2016-08-31 23:30:00	5

26195 rows × 1 columns

Будем предсказывать кол-во взятых в прокат велосипедов на неделю вперед по данным за последние полгода. Понятно, что так мы сможем учесть и месячную, и недельную сезонность, в то же время мы не можем ничего говорить о годовой сезонности, поэтому данные почти за два года будут излишними, более того, из-за них можно будет не уследить за краткосрочным трендом.

In [30]:

```
1 test_size = 48*7
2 train_size = 48*30*3
3 train = series.tail(test_size + train_size).head(train_size)
4 test = series.tail(test_size)
```

In [31]:

```
1 train.to_csv('train_ts.csv')
2 test.to_csv('test_ts.csv')
```

Взглянем на ряд

In [13]:

```
plt.figure(figsize=(20, 6))
sns.set_style('darkgrid')

plt.title('Обучающая часть')

plt.plot(train.index, train['count'].values, alpha=0.8)
plt.xlabel('Начало поездки')
plt.ylabel('Количество')

plt.show()
```

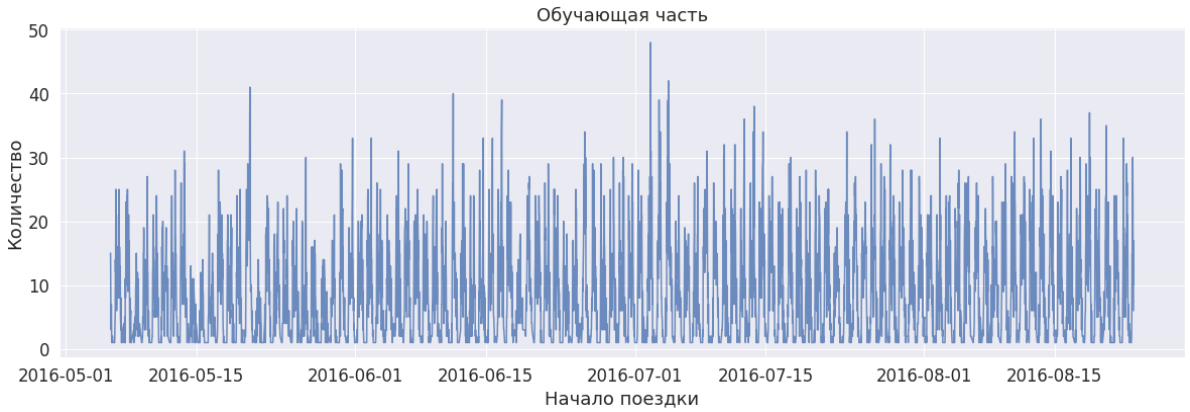

In [14]:

```
plt.figure(figsize=(20, 6))
sns.set_style('darkgrid')

plt.title('Тестовая часть')

plt.plot(test.index, test['count'].values, alpha=0.8)
plt.xlabel('Начало поездки')
plt.ylabel('Количество')

plt.show()
```

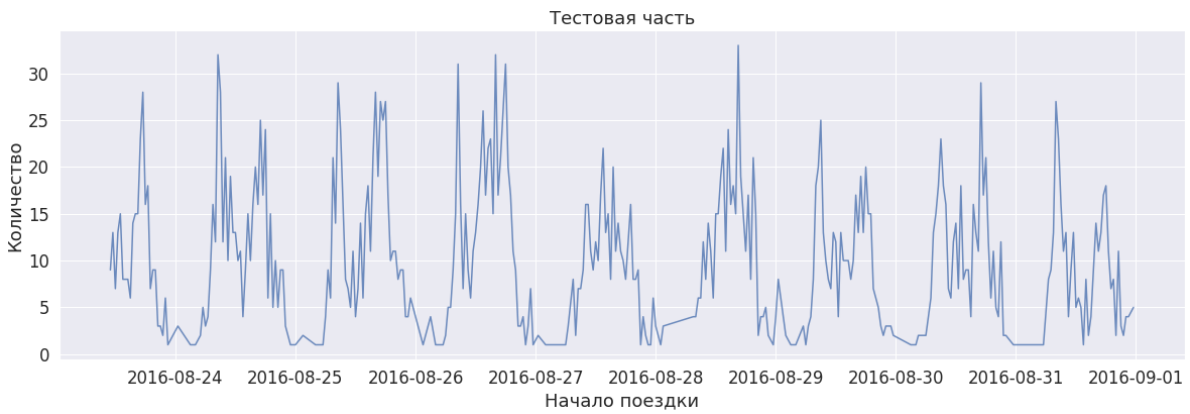

1. Бейзлайны - среднее и последнее наблюдаемое значение.

Во временных рядах сильными бейзлайнами являются среднеее и последнее наблюдаемое значение. Благодаря ним поймем, на какой MSE стоит ориентироваться.

In [0]:

```
mean_preds = np.array([train['count'].mean()] * test_size)
```

In [79]:

```
def print_preds(test, preds, name):
    plt.figure(figsize=(20, 6))
    sns.set_style('darkgrid')

    plt.title('Тестовая часть и предсказания')

    plt.plot(test.index, test['count'].values, alpha=0.8,
             label='test')
    plt.plot(test.index, preds, alpha=0.9,
             label=name + ' preds')
    plt.xlabel('Начало поездки')
    plt.ylabel('Количество')
    plt.legend()
    plt.show()
```

In [17]:

```
mse = MSE(test['count'].values, mean_preds)
print(f'MSE = {mse}')
print_preds(test, mean_preds, name='mean')
```

```
MSE = 54.57371512468156
```

In [18]:

```
last_preds = np.array([train['count'].values[-1]] * test_size)
mse = MSE(test['count'].values, last_preds)
print(f'MSE = {mse}')
print_preds(test, mean_preds, name='last')
```

```
MSE = 72.96130952380952
```

Пока будем равняться на бейзлайн средних предсказаний

2. Подбор параметров для SARIMA

Из анализа проведенного выше понятно, что есть месячная и недельная сезонность. Рассмотрим дневную.

In [19]:

```
gc.collect()
decomposed = seasonal_decompose(train['count'].values, freq=48)

plt.figure(figsize=(14, 11))

plt.subplot(411)
plt.plot(train.index, decomposed.trend)
plt.title('Тренд')

plt.subplot(412)
plt.plot(train.index, decomposed.seasonal)
plt.title('Дневная сезонность')

plt.subplot(413)
plt.plot(train.index, decomposed.resid)
plt.title('Остатки')

plt.tight_layout()
```

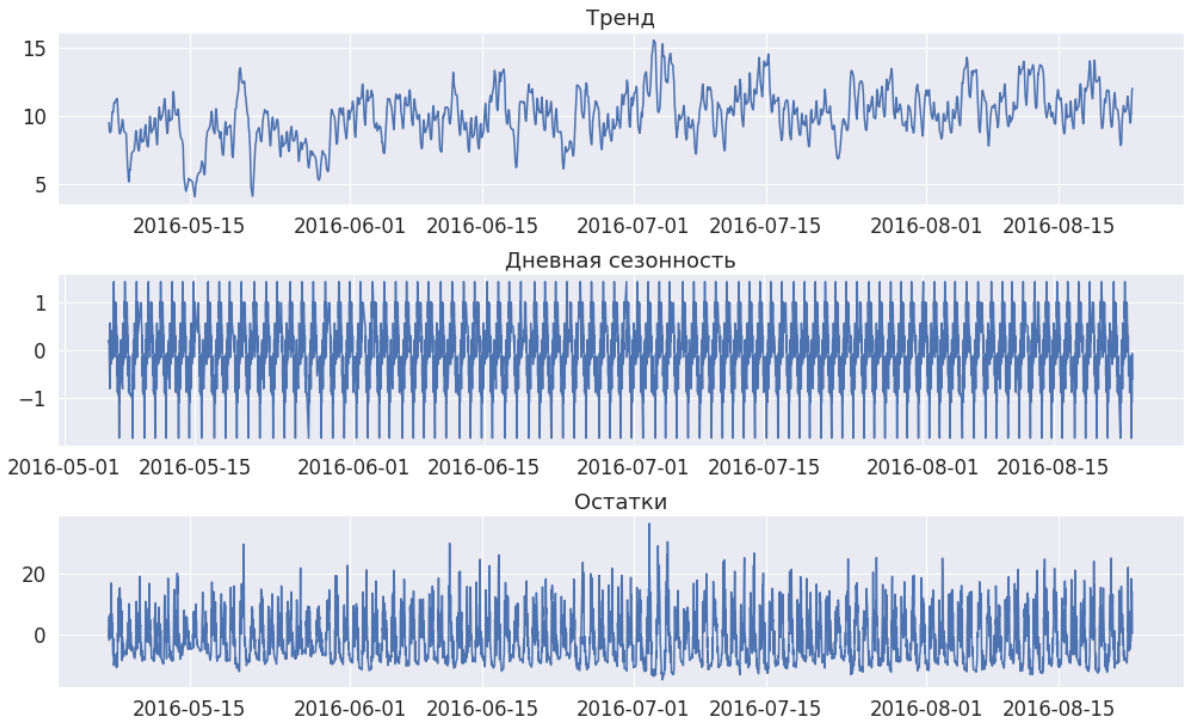

Дневная сезонность действительно очевидна.

Для подбора параметров для SARIMA нужно смотреть на значимые лаги коррелограммы после приведения ряда к стационарному.

In [0]:

```
train_count = train['count'].values
```

In [21]:

```
1 kpss(train_count)
```

Out[21]:

```
(1.735283654917425,
 0.01,
 31,
 {'1%': 0.739, '10%': 0.347, '2.5%': 0.574, '5%': 0.463})
```

Как видим, пока что гипотеза о стационарности отвергается

In [0]:

```
1 diff = train_count[1:] - train_count[:(-1)]  # снимаем тренд
2 diff = diff[(48*30):] - diff[:(-48*30)]
3 diff = diff[(48*7):] - diff[:(-48*7)]
4 diff = diff[(48):] - diff[:(-48)]
```

In [23]:

```
1 kpss(diff)
```

Out[23]:

```
(0.0047162543491004235,
 0.1,
 27,
 {'1%': 0.739, '10%': 0.347, '2.5%': 0.574, '5%': 0.463})
```

Теперь не отвергается

In [24]:

```
fig = plt.figure(figsize=(15, 9))

ax = fig.add_subplot(211)
fig = sm.graphics.tsa.plot_acf(diff, lags=150, ax=ax)
ax.set_xticks(np.arange(0, 151, 5))

ax = fig.add_subplot(212)
fig = sm.graphics.tsa.plot_pacf(diff, lags=150, ax=ax)
ax.set_xticks(np.arange(0, 151, 5))

plt.setp(ax.get_xticklabels(), fontsize=13)
ax.set_xlabel('lag')

plt.show()
```

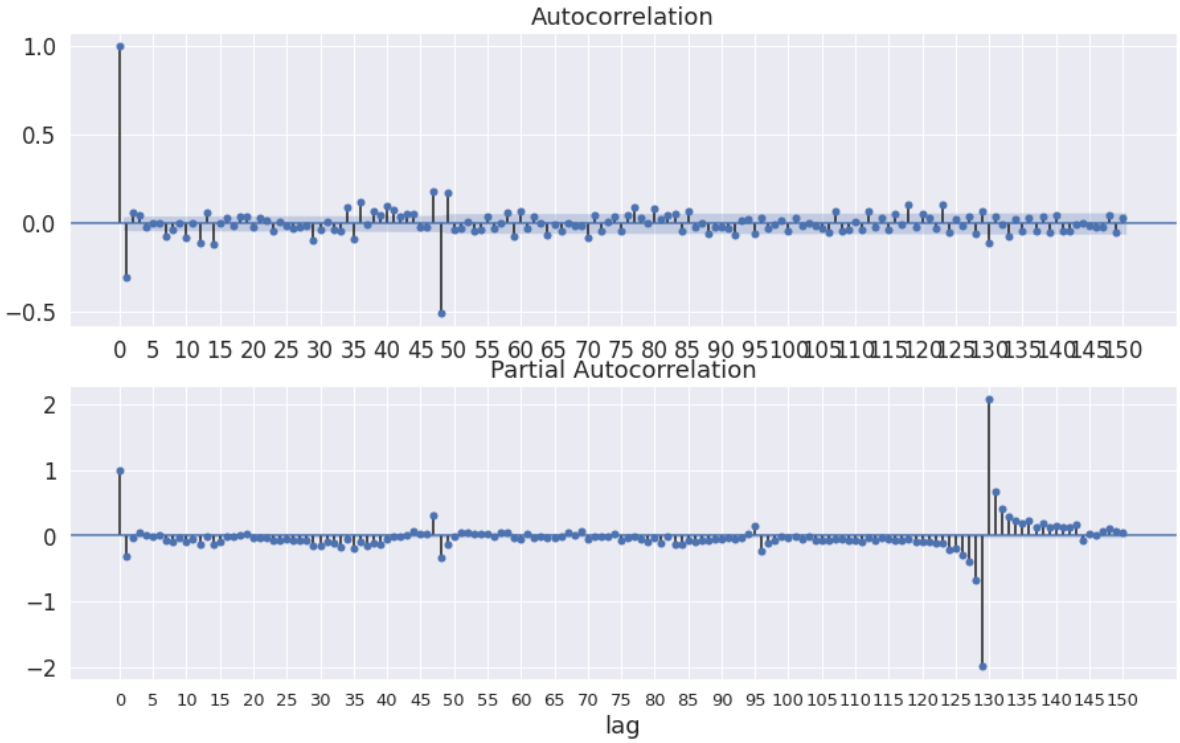

Результат: автокорреляция принимает большие значения для первых 2-х лагов, поэтому возьмем p = 2. Частичная автокорррреляция принимает большие значения для первых трех лагов, поэтому возьмем q = 3. На лаги, соответствующие сезонности, не обращаем внимание, так как дифференциируемость не обязательнос снимает всю сезонность.

3. Обучение SARIMAX

In [25]:

```
%%time
param = (2, 1, 3)
param_seasonal = (2, 1, 2, 48)
model = sm.tsa.statespace.SARIMAX(train_count, order=param,
                                  seasonal_order=param_seasonal)
model = model.fit()
print('ARIMA{}x{} - AIC: {:.2f}'.format(param,
                                        param_seasonal,
                                        model.aic))
```

```
ARIMA(2, 1, 3)x(2, 1, 2, 48) - AIC: 26330.06
CPU times: user 2h 17min 32s, sys: 1h 16min 14s, total: 3h 33min 47s
Wall time: 54min 2s
```

In [0]:

```
preds = model.forecast(steps=48*7)
```

In [27]:

```
mse = MSE(test['count'].values, preds)
print(f'MSE = {mse}')
print_preds(test, preds, name='sarimax')
```

```
MSE = 56.70103145859546
```

Результат: SARIMAX плохо справляется, результат даже хуже среднего

4. fb prophet

In [0]:

```
from fbprophet import Prophet
```

In [41]:

```
1 train.head()
```

Out[41]:

time	count
2016-05-05 18:30:00	15
2016-05-05 19:00:00	15
2016-05-05 19:30:00	10
2016-05-05 20:00:00	3
2016-05-05 20:30:00	4

In [0]:

```
1 train_for_prophet = train.reset_index()
2 train_for_prophet.columns = ['ds', 'y']
```

In [43]:

```
1 train_for_prophet.head()
```

Out[43]:

	ds	y
0	2016-05-05 18:30:00	15
1	2016-05-05 19:00:00	15
2	2016-05-05 19:30:00	10
3	2016-05-05 20:00:00	3
4	2016-05-05 20:30:00	4

In [44]:

```
1 m = Prophet()
2 m.fit(train_for_prophet)
```

```
INFO:fbprophet:Disabling yearly seasonality. Run prophet with yearly_s
easonality=True to override this.
```

Out[44]:

```
<fbprophet.forecaster.Prophet at 0x7f01a41f3da0>
```

In [0]:

```
1 future = m.make_future_dataframe(periods=48*7)
2 forecast = m.predict(future)
```

In [0]:

```
preds = forecast['yhat'].values
```

In [62]:

```
mse = MSE(test['count'].values, preds[-48*7:])
print(f'MSE = {mse}')
print_preds(test, preds[-48*7:], name='prophet')
```

```
MSE = 103.9387186843022
```

Результат: prophet справляется совсем плохо

5. Экзогенные факторы.

Для этого скачаем данные о погодных условиях.

In [54]:

```
weather_data = pd.read_csv('cycle-share-dataset/weather.csv',
                           parse_dates=[0], na_values='-')

weather_data.head()
```

Out[54]:

	Date	Max_Temperature_F	Mean_Temperature_F	Min_TemperatureF	Max_Dew_Point_F	Mean
0	2014-10-13	71	62.0	54	55	
1	2014-10-14	63	59.0	55	52	
2	2014-10-15	62	58.0	54	53	
3	2014-10-16	71	61.0	52	49	
4	2014-10-17	64	60.0	57	55	

5 rows × 21 columns

При анализе влияния погодных условий на количесво поездок мы получили, что значимыми являются такие показатели, как температура, влажность и точка росы.

Добавим их в нашу модель.

Добавим, сначала, в наш временной ряд признак даты

In [55]:

```
series_w_date = series.reset_index()
series_w_date['date'] = series_w_date.time.dt.normalize()

series_w_date.head()
```

Out[55]:

	time	count	date
0	2014-10-13 10:30:00	12	2014-10-13
1	2014-10-13 11:30:00	108	2014-10-13
2	2014-10-13 12:00:00	42	2014-10-13
3	2014-10-13 12:30:00	42	2014-10-13
4	2014-10-13 13:00:00	36	2014-10-13

In [56]:

```
weather_signif = weather_data.loc[:, ['Date', 'Mean_Temperature_F',
                                      'MeanDew_Point_F', 'Mean_Humidity']].cop
```

Теперь, соединим две таблицы.

In [57]:

```
series_exog = series_w_date.merge(weather_signif, how='left',
                                  left_on='date', right_on='Date')

series_exog.head()
```

Out[57]:

	time	count	date	Date	Mean_Temperature_F	MeanDew_Point_F	Mean_Humidity
0	2014-10-13 10:30:00	12	2014-10-13	2014-10-13	62.0	51	68
1	2014-10-13 11:30:00	108	2014-10-13	2014-10-13	62.0	51	68
2	2014-10-13 12:00:00	42	2014-10-13	2014-10-13	62.0	51	68
3	2014-10-13 12:30:00	42	2014-10-13	2014-10-13	62.0	51	68
4	2014-10-13 13:00:00	36	2014-10-13	2014-10-13	62.0	51	68

In [64]:

```
series_exog.to_csv('series_exog.csv')
```

Разделим временной ряд на обучающую и тестовую выборки.

In [70]:

```
test_size = 48*7
train_size = 48*30*3
train_exog = series_exog.tail(test_size + train_size).head(train_size)
test_exog = series_exog.tail(test_size)
```

In [71]:

```
train_count = train_exog['count'].values
test_count = test_exog['count'].values

exog = train_exog.loc[:,['Mean_Temperature_F',
                         'MeanDew_Point_F',
                         'Mean_Humidity']].values
```

Обучим модель с подобранными ранее параметрами и добавлением данных о погоде, как экзогенного фактора.

In [65]:

```
%%time
param = (2, 1, 3)
param_seasonal = (2, 1, 2, 48)
model = sm.tsa.statespace.SARIMAX(train_count, order=param,
                                  seasonal_order=param_seasonal,
                                  exog=exog)
model = model.fit()
print('ARIMA{}x{} - AIC: {:.2f}'.format(param,
                                        param_seasonal,
                                        model.aic))
```

```
ARIMA(2, 1, 3)x(2, 1, 2, 48) - AIC: 26379.94
CPU times: user 1h 17min 44s, sys: 28.9 s, total: 1h 18min 13s
Wall time: 19min 55s
```

Предсказание модели.

In [95]:

```
test_exog_values = test_exog.loc[:,['Mean_Temperature_F',
                         'MeanDew_Point_F',
                         'Mean_Humidity']].values

preds_exog = model.forecast(steps=48*7, exog=test_exog_values)
```

In [96]:

```
def print_preds_exog(test, exog, preds, name):
    plt.figure(figsize=(20, 12))
    sns.set_style('darkgrid')

    plt.subplot(211)
    plt.title('Тестовая часть и предсказания')

    plt.plot(test.index, test['count'].values, alpha=0.8,
             label='test')
    plt.plot(test.index, preds, alpha=0.9,
             label=name + ' preds')

    plt.xlabel('Начало поездки')
    plt.ylabel('Количество')
    plt.legend()

    plt.subplot(212)
    plt.title('Экзогенные факторы')
    for column in exog.columns:
        plt.plot(test.index, exog[column], label=column)
    plt.xlabel('Начало поездки')
    plt.legend()
    plt.tight_layout()
```

In [97]:

```
print_preds_exog(test,test_exog.loc[:,['Mean_Temperature_F',
                         'MeanDew_Point_F',
                         'Mean_Humidity']], preds_exog, name='sarimax + exog')
```

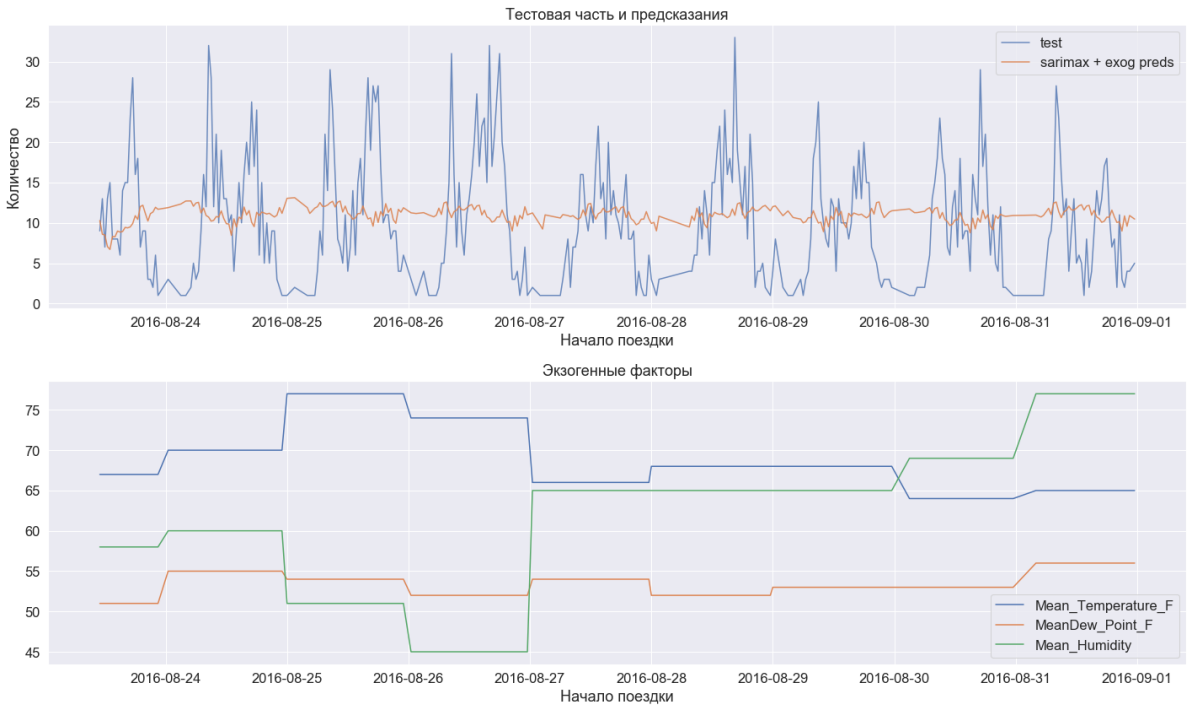

Качество MSE построенной модели.

In [99]:

```
mse = MSE(test_count, preds_exog)
print(f'MSE = {mse}')
```

```
MSE = 56.717890860833016
```

Таким образом, мы не смогли улучшить качество предсказания с помощью добавления экзогенных факторов погодных условий.

Отдельно стоит отметить, что при использовании погодных условий, прежде чем предсказывать количество поездок, нужно отдельно предсказывать погоду на неделю вперёд, что вносит дополнительную ошибку, при условии, что мы не можем достаточно хорошо предсказывать погодные условия.

В качестве экзогенных факторов стоит добавить такие заранее предсказываемые признаки, как наличие праздника/выходного дня и т.д.

In [ ]:

```

```