Поиск точек посадки пассажиров

В этом ноутбуке реализованы различные алгоритмы для предсказания точек посадки пассажиров. Начнём с самых простых идей, затем будем их усложнять.

In [1]:

```
import pandas as pd
import numpy as np
from tqdm import tqdm_notebook
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
from sklearn.decomposition import PCA
from sklearn.manifold import TSNE
from umap.umap_ import UMAP

from sklearn.preprocessing import StandardScaler

from sklearn.cluster import \
    KMeans, \
    AgglomerativeClustering, \
    DBSCAN, \
    SpectralClustering

warnings.filterwarnings('ignore')
sns.set_style('whitegrid')
sns.set(font_scale=1.5)
```

In [2]:

```
data = pd.read_csv('data/3k_data_features', index_col=0)
```

In [3]:

```
1 data.head(120)
```

Out[3]:

	begin	session	status	ts	x	y	delay	dist	av_speed	x_diff
0	1	0	0	0	0.000000	0.000000	0	0.000000	NaN	0.000000
1	0	0	0	9	-0.644802	0.291129	9	0.707478	0.078609	-0.644802
2	0	0	0	17	-0.243663	1.229173	8	1.020216	0.127527	0.401139
3	0	0	0	25	2.447144	13.056778	8	12.129826	1.516228	2.690807
4	0	0	0	33	-3.184499	21.475057	8	10.128318	1.266040	-5.631643
...	...	...	...	...	...	...	...	...	...	...
115	1	1	0	0	0.000000	-0.000000	0	2740.430003	inf	0.000000
116	0	1	0	6	-0.735076	-0.143670	6	0.748985	0.124831	-0.735076
117	0	1	0	8	-0.735076	-0.143670	2	0.000000	0.000000	0.000000
118	0	1	0	14	-1.099865	-0.554960	6	0.549754	0.091626	-0.364788
119	0	1	0	17	-1.448817	-0.396501	3	0.383246	0.127749	-0.348953

120 rows × 12 columns

In [4]:

```
1 data[data.session == 144].head()
```

Out[4]:

	begin	session	status	ts	x	y	delay	dist	av_speed	x_diff	y_diff	angle
15868	1	144	0	0	0.0	0.0	0	370.460669	inf	0.0	0.0	0.0
15869	0	144	0	8	0.0	0.0	8	0.000000	0.0	0.0	0.0	0.0
15870	0	144	1	16	0.0	0.0	8	0.000000	0.0	0.0	0.0	0.0
15871	0	144	1	24	0.0	0.0	8	0.000000	0.0	0.0	0.0	0.0
15872	0	144	1	32	0.0	0.0	8	0.000000	0.0	0.0	0.0	0.0

Глава 1. Наивные решения

1. Первая точка со статусом 2

Идея: водитель меняет статус, когда к нему садится пассажир.

Первое тривиальное решение, которое приходит на ум - просто брать первую точку, на которой было зафиксировано, что машина едет с пассажиром.

In [5]:

```
def first_status_2(data):
    d = {}

    session_values = np.unique(data.session.values)
    for session in tqdm_notebook(session_values):
        session_data = data[data.session == session]
        pickup_row = session_data[session_data.status == 2].head(1)
        d[session] = (pickup_row.x.values[0], pickup_row.y.values[0])

    return d
```

2. Середина отрезка между точками со статусами 1 и 2

Идея: водитель меняет статус с опозданием.

Так как водитель может забывать изменить статус сразу же, будем брать точку чуть раньше, а именно середину между последней точкой со статусом 1 ("подъезжает") и первой точкой со статусом 2 ("едет с пассажиром").

In [6]:

```
def middle_1_2(data):
    d = {}

    session_values = np.unique(data.session.values)
    for session in tqdm_notebook(session_values):
        session_data = data[data.session == session]
        pickup_row_1 = session_data[session_data.status == 1].tail(1)
        pickup_row_2 = session_data[session_data.status == 2].head(1)
        d[session] = ((pickup_row_1.x.values[0] + pickup_row_2.x.values[0])/2,
                      (pickup_row_1.y.values[0] + pickup_row_2.y.values[0])/2)

    return d
```

3. Последняя точка со статусом 1, если точка со статусом 2 далеко

Идея: если водитель ставит статус "подъезжает", но следующая точка со статусом "едет с пассажиром" достаточно далеко, то скорее всего водитель забыл переключить статус вовремя, и тогда в качестве ответа будем брать последнюю точку со статусом 1, иначе первую со статусом 2.

Чтобы понять, какое расстояние считать "далёким", а какое - нет, посмотрим, как распределены расстояния при переключении статуса с 1 на 2.

In [7]:

```
distances = []

session_values = np.unique(data.session.values)
for session in tqdm_notebook(session_values):
    session_data = data[data.session == session]
    st2_row = session_data[session_data.status == 2].head(1)
    distances.append(st2_row.dist.values[0])

distances = np.array(distances)
```

```
HBox(children=(IntProgress(value=0, max=3000), HTML(value='')))
```

In [8]:

```
plt.title('boxplot расстояний',
          fontsize=14)
sns.boxplot(distances)
plt.show()
```

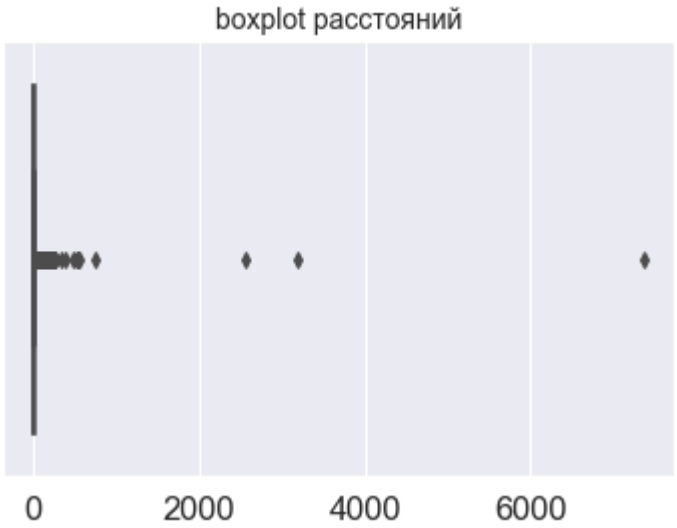

In [9]:

```
plt.figure(figsize=(10, 7))
plt.title('Гистограмма расстояний между статусами 1 и 2',
          fontsize=14)
sns.distplot(distances, bins=200, kde=True, rug=True)
plt.xlim(0, 1000)
plt.show()
```

Там где значения блихки к 0, очевидно, точка посадки - это и есть первая точка со статусом 2.
Взглянем на ненулевые значения и уберем из рассмотрения чересчур большие расстояния.

In [10]:

```
clean_distances = distances[distances != 0.0]
clean_distances = clean_distances[clean_distances < 200]
```

In [11]:

```
plt.title('boxplot расстояний',
          fontsize=14)
sns.boxplot(clean_distances)
plt.show()
```

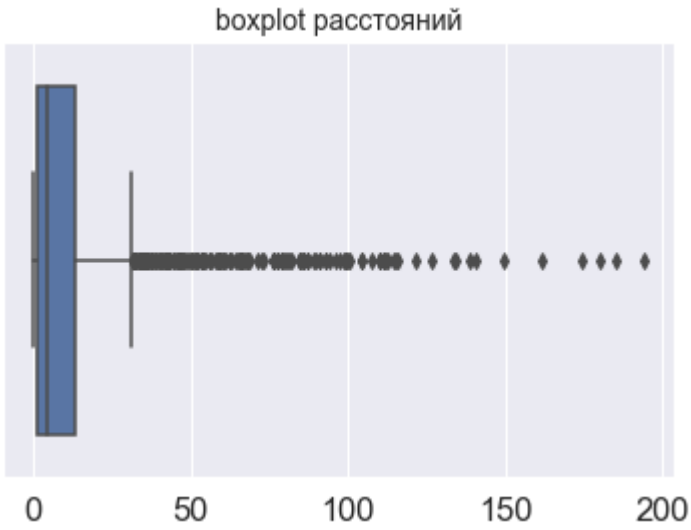

In [12]:

```
plt.figure(figsize=(10, 7))
plt.title('Гистограмма расстояний между статусами 1 и 2',
          fontsize=14)
sns.distplot(clean_distances, bins=20, kde=True, rug=True,
             rug_kws={'alpha': 0.1})
plt.show()
```

Как видим, после небольшой "чистки данных", получилось, что значения, больше 30, уже считаются выбросами. Возьмем 30 в качестве пороговой константы по умолчанию.

In [13]:

```
def distance_1_2(data, threshold=30):
    d = {}

    session_values = np.unique(data.session.values)
    for session in tqdm_notebook(session_values):
        session_data = data[data.session == session]
        st1_row = session_data[session_data.status == 1].tail(1)
        st2_row = session_data[session_data.status == 2].head(1)
        dist = st2_row.dist.values[0]
        if dist > threshold:
            d[session] = (st1_row.x.values[0],
                          st1_row.y.values[0])
        else:
            d[session] = (st2_row.x.values[0],
                          st2_row.y.values[0])

    return d
```

Глава 2. Решения с использованием кластеризации

1. Поиск точек посадки с использованием алгоритмов кластеризации.

Попробуем использовать рассмотренные на лекциях алгоритмы кластеризации для улучшения предыдущих двух подходов к поиску точек посалдки.

Для кластеризации будем использовать последние две точки со статусом 0, все точки со статусом 1 и первые две точки со статусом 2.

Для кластеризации будем использовать несколько признаков - координаты, скорость и направление движения.

Будем разделять точки на три кластера. Идея заключается в том, что в реальности не все точки со статусом 1 относятся к реальному ожиданию клиента. Разделив точки на три кластера, мы разделим точки со статусом 1 на точки, в которых водитель ещё подъезжал к клиенту, точки в которых водитель реально ждал клиента и точки, в которых водитель уже ехал с клиентом. Предполоагается, что в каждой группе точки схожи по направлению движения и скорости. Чтобы кластеры были отделены друг от друга по времени, будем также использовать признак `ts`(временная метка .

Визуализируем значала разбиение на кластеры для нескольких сессий.

KMeans:

In [14]:

```
def visualize_clustering(fit_predict_method, name = ''):
    session_values = np.unique(data.session.values)

    plt.figure(figsize=(20, 20))
    for i, session in tqdm_notebook(enumerate(session_values[:6])):

        session_data = data[data.session == session]
        median_dist = np.mean(session_data[session_data.status==1].dist.values

        status_1_data = session_data[session_data.status == 1].loc[:, ['x',
                                                                       'y',
                                                                       'ts',
                                                                       'av_spe
                                                                       'angle'
        status_0_data = session_data[session_data.status == 0].loc[:, ['x',
                                                                       'y',
                                                                       'ts',
                                                                       'av_spe
                                                                       'angle'
        status_2_data = session_data[session_data.status == 2].loc[:, ['x',
                                                                       'y',
                                                                       'ts',
                                                                       'av_spe
                                                                       'angle'

        status_data = pd.concat([status_0_data.iloc[-1:, :],
                                 status_1_data,
                                 status_2_data.iloc[:1, :]],
                                axis=0)

        scaler = StandardScaler(with_mean=False)
        status_data.iloc[:, :] = scaler.fit_transform(status_data.copy())
        # session_data = session_data[session_data.status != 1].loc[:, ['x', '

        y_pred = fit_predict_method(status_data)

        plt.subplot(3, 3, i+1)
        plt.title(f'session {i}')
        plt.xlabel('X')
        plt.ylabel('Y')

        status_data.iloc[:, :] = scaler.inverse_transform(status_data.copy())
        plt.scatter(status_data['x'].values, status_data['y'].values,
                    c=y_pred, alpha=1, s=50, cmap='Set1')

        plt.plot(status_data['x'].values, status_data['y'].values, alpha=0.5)
    #     plt.scatter(session_data['x'].values, session_data['y'].values,
    #                 alpha=0.2, s=25)

    plt.tight_layout()
```

In [15]:

```
visualize_clustering(KMeans(n_clusters=3,
                            random_state=42,
                            n_init=100,
                            max_iter=1000).fit_predict)
```

```
HBox(children=(IntProgress(value=1, bar_style='info', max=1), HTML(val
ue='')))
```

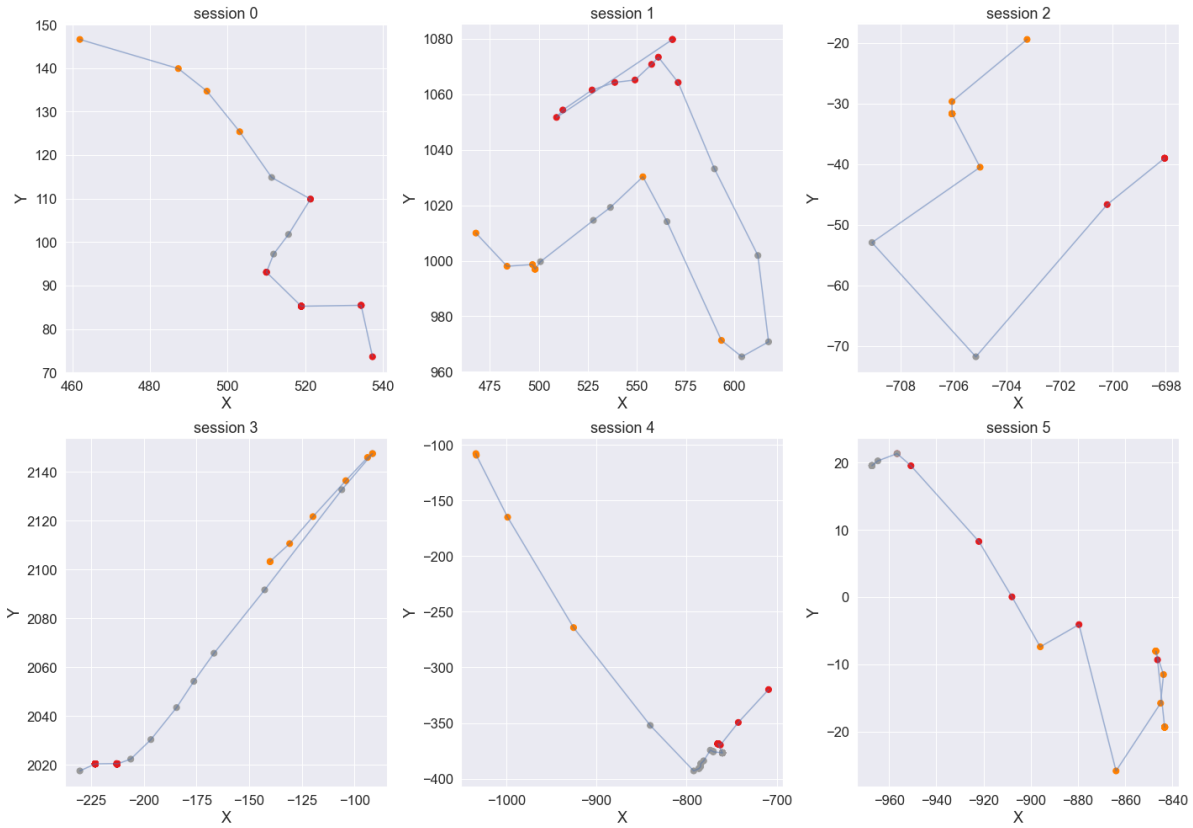

Визуально, можно видеть, что во многих случаях алгоритм правильно кластеризовал рассмотренные точки сессии.

Попробуем теперь использовать другие, менее тривиальные алгоритмы кластеризации.

Например, аггломеративная кластеризация.

In [16]:

```
visualize_clustering(AgglomerativeClustering(n_clusters=3,
                                              linkage='ward').fit_predict)
```

```
HBox(children=(IntProgress(value=1, bar_style='info', max=1), HTML(val
ue='')))
```

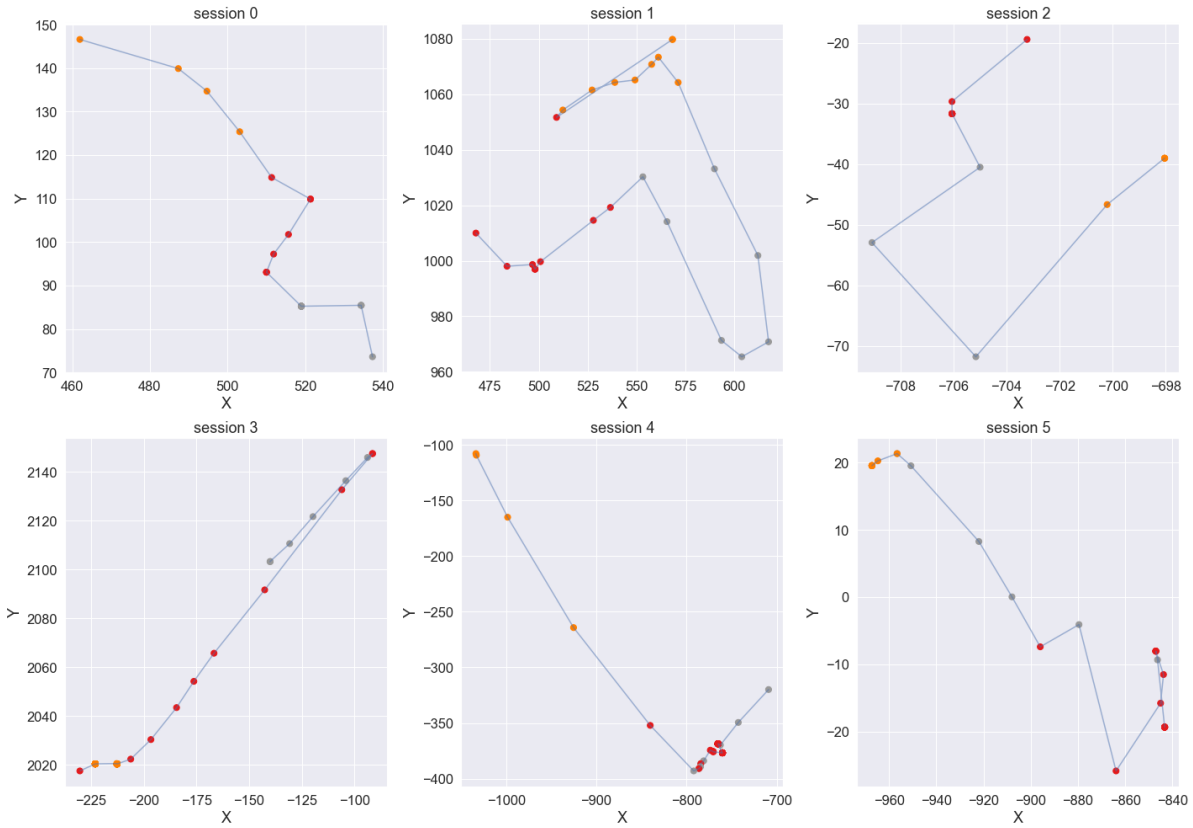

Для метода спектральной кластеризации.

In [17]:

```
1 visualize_clustering(SpectralClustering(n_clusters=3).fit_predict)
```

```
HBox(children=(IntProgress(value=1, bar_style='info', max=1), HTML(val
ue='')))
```

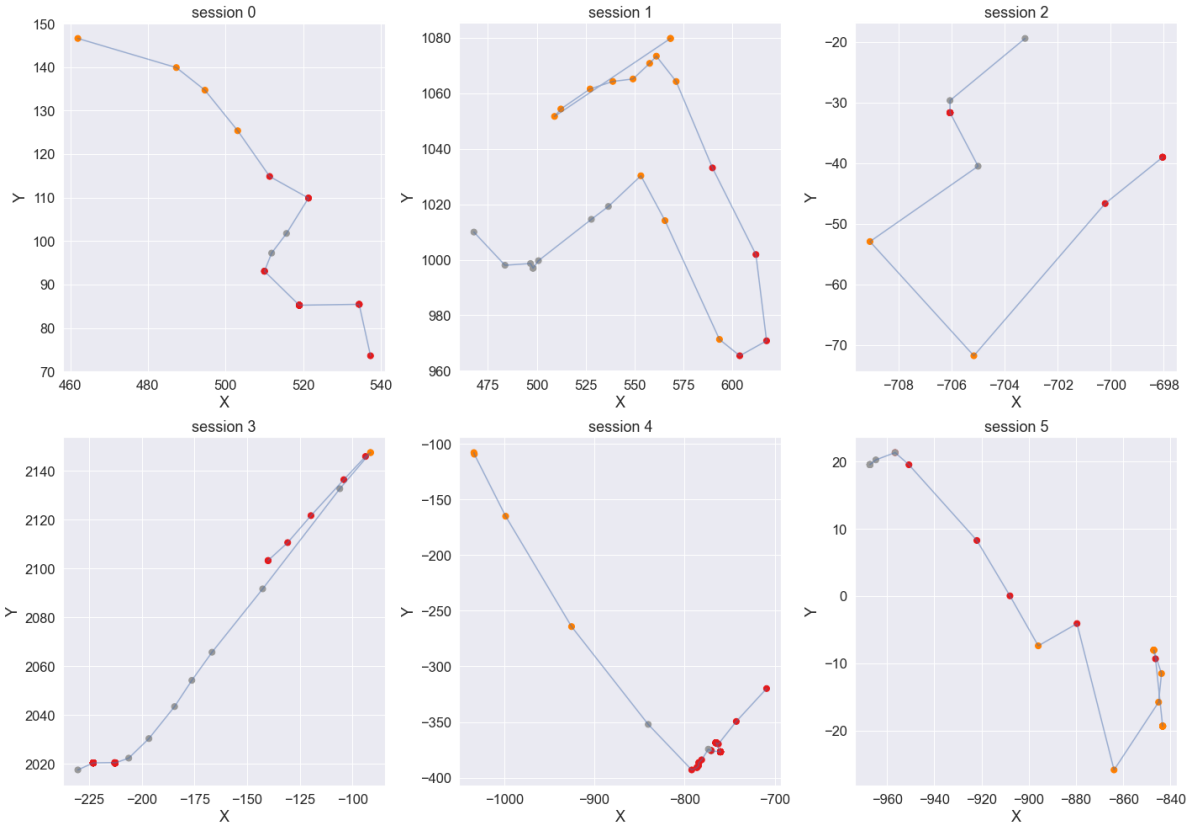

В каждом случае алгоритмы разные алгоритмы кластеризации по-разному сработали на предложенных данных.

В качестве одного из способов нахождения точки посадки логично использовать последнюю точку (с точки зрения времени) кластера, отвечающего за ожидание (среднего кластера). Т.к. разные алгориитмы в разных случаях дали хорошие результаты, то усредним найденный ответ (по обеим координатам для трёх рассмотренных алгоритмов).

Замечание

В любом случае, будут сессии, которые кластеризовать не получится.

Будем добавлять признак кластера только для тех сессий, в которых среднее расстояние между точками "среднего" кластера не превосходят некоторого порога.

Чтобы подобрать порог, посмотрим на рапределение расстояний между точками "среднего" кластера.

In [18]:

```
def clustering_prediction(fit_predict_methods):
    session_values = np.unique(data.session.values)

    session_predictions = []
    cluster_distances = []
    for i, session in tqdm_notebook(enumerate(session_values), total=len(sessi

        # Данные рассматриваемой сессии
        session_data = data[data.session == session]
        session_data = session_data[session_data.ts != 0]

        columns = ['x', 'y', 'ts', 'av_speed', 'angle', 'dist']

        # Выделяем из данных сессии данные с нужными статусами
        status_1_data = session_data[session_data.status == 1].loc[:, columns]
        status_0_data = session_data[session_data.status == 0].loc[:, columns]
        status_2_data = session_data[session_data.status == 2].loc[:, columns]

        # Соединяем всё вместе
        status_data_w_dist = pd.concat([status_0_data.iloc[-2:, :],
                                        status_1_data,
                                        status_2_data.iloc[:2, :]],
                                        axis=0)

        status_data = status_data_w_dist.loc[:, columns[:-1]].copy()

        #Стандартизуем данные
        scaler = StandardScaler(with_mean=False)
        status_data.iloc[:, :] = scaler.fit_transform(status_data.copy())

        x_preds = []
        y_preds = []
        dist_preds = []
        for method in fit_predict_methods:
            pred = method(status_data)

            # Найдём точки, где сменяется кластер
            candidates = []
            for j in range(len(pred) - 1):
                if pred[j] != pred[j+1]:
                    candidates.append(j)

            # Если кластера всего два, то возьмём последнюю рассматриваемую
            # точку в качестве правой границы
            if len(candidates) == 1:
                candidates.append(len(pred) - 1)

            # Предсказания и среднее расстояние в кластере
            x_preds.append(status_data_w_dist['x'].values[candidates[-1]])
            y_preds.append(status_data_w_dist['y'].values[candidates[-1]])
            dist_preds.append(np.mean(status_data_w_dist['dist'].values[candid


        x_pred = np.mean(x_preds)
        y_pred = np.mean(y_preds)

        session_predictions.append([i, x_pred, y_pred])
        cluster_distances.append(np.mean(dist_preds))

```

```
    return session_predictions, cluster_distances

fit_predict_methods = [KMeans(n_clusters=3,
                              random_state=42,
                              n_init=100,
                              max_iter=1000,
                              n_jobs=-1).fit_predict,
                       AgglomerativeClustering(n_clusters=3,
                                               linkage='ward').fit_predict,
                       SpectralClustering(n_clusters=3, n_jobs=-1).fit_predict


predictions, cluster_distances = clustering_prediction(fit_predict_methods)
```

```
HBox(children=(IntProgress(value=0, max=3000), HTML(value='')))
```

In [19]:

```
cluster_distances = np.array(cluster_distances)
```

In [20]:

```
plt.figure(figsize=(15, 6))
plt.title('boxplot средних расстояний в кластере',
          fontsize=14)
sns.boxplot(cluster_distances)
plt.show()
```

Уберём слишком большие расстояния и нулевые значения.

In [21]:

```
clean_cluster_distances = cluster_distances[cluster_distances < 200]
clean_cluster_distances = clean_cluster_distances[clean_cluster_distances != 0

plt.figure(figsize=(15, 6))
plt.title('boxplot средних расстояний в кластере',
          fontsize=14)
sns.boxplot(clean_cluster_distances)
plt.show()
```

По ящику с усами сделаем вывод, что в качестве порога стоит взять значение 50.

Предсказания для сессий, которые удовлетворяют найденным требованиям.

In [25]:

```
predictions = np.array(predictions)

border = 50
valid_predictions = predictions[cluster_distances < border]
```

In [26]:

```
1 valid_predictions
```

Out[26]:

```
array([[ 0.00000000e+00,  5.10017269e+02,  9.30667056e+01],
       [ 1.00000000e+00,  5.35756838e+02,  1.02008594e+03],
       [ 2.00000000e+00, -7.05152838e+02, -7.18097034e+01],
       ...,
       [ 2.99600000e+03,  5.77368044e+02, -3.90836663e+02],
       [ 2.99700000e+03,  4.18607354e+02, -1.03685689e+03],
       [ 2.99900000e+03,  4.69970686e+02,  3.37197706e+02]])
```

2. Создание датасета статистик по сессиям и поиск в нем кластерной структуры

Чтобы дальше предлагать решения с разбором случаев, в зависимости от того, как выглядит сессия, с которой мы работаем, попробуем сделать дасатет для сессий, а затем визуализировать его методами понижения размерности PCA, t-SNE, UMAP. Возможно, получится найти в нем кластерную структуру.

Для каждой сессии будем в качестве признаков брать общее кол-во точек в ней, кол-во точек в зависимости от статуса, среднюю скорость в зависимости от статуса, суммарное время для каждого статуса, суммарное расстояние для каждого статуса, а также направление движения, скорость, время и расстояние в точках перехода от одного статуса к другому.

In [27]:

```
def session_df(data):
    session_features = []

    session_values = np.unique(data.session.values)
    for session in tqdm_notebook(session_values):
        session_data = data[data.session == session].fillna(0)
        session_data = session_data.replace([np.inf, -np.inf], 0.)

        total_points = session_data.shape[0]
        st0_points = session_data[session_data.status == 0].shape[0]
        st1_points = session_data[session_data.status == 1].shape[0]
        st2_points = session_data[session_data.status == 2].shape[0]

        speed = session_data.av_speed.values.mean()
        st0_speed = session_data[session_data.status == 0].av_speed.values.mea
        st1_speed = session_data[session_data.status == 1].av_speed.values.mea
        st2_speed = session_data[session_data.status == 2].av_speed.values.mea

        time = session_data.ts.values.sum()
        st0_time = session_data[session_data.status == 0].ts.values.sum()
        st1_time = session_data[session_data.status == 1].ts.values.sum()
        st2_time = session_data[session_data.status == 2].ts.values.sum()

        dist = session_data.dist.values.sum()
        st0_dist = session_data[session_data.status == 0].dist.values.sum()
        st1_dist = session_data[session_data.status == 1].dist.values.sum()
        st2_dist = session_data[session_data.status == 2].dist.values.sum()

        st01_dist = session_data[session_data.status == 1].head(1).dist.values
        st12_dist = session_data[session_data.status == 2].head(1).dist.values

        st01_angle = session_data[session_data.status == 1].head(1).angle.valu
        st12_angle = session_data[session_data.status == 2].head(1).angle.valu

        st01_speed = session_data[session_data.status == 1].head(1).av_speed.v
        st12_speed = session_data[session_data.status == 2].head(1).av_speed.v

        st01_time = session_data[session_data.status == 1].head(1).ts.values[0
        st12_time = session_data[session_data.status == 2].head(1).ts.values[0

        features_list = [session, total_points, st0_points, st1_points, st2_po
                         speed, st0_speed, st1_speed, st2_speed,
                         time, st0_time, st1_time, st2_time,
                         dist, st0_dist, st1_dist, st2_dist,
                         st01_dist, st12_dist, st01_angle, st12_angle,
                         st01_speed, st12_speed, st01_time, st12_time]

        session_features.append(features_list)

    df = pd.DataFrame(session_features,
                      columns=['session', 'total_points', 'st0_points',
                               'st1_points', 'st2_points', 'speed',
                               'st0_speed', 'st1_speed', 'st2_speed',
                               'time', 'st0_time', 'st1_time', 'st2_time',
                               'dist', 'st0_dist', 'st1_dist', 'st2_dist',
                               'st01_dist', 'st12_dist', 'st01_angle', 'st12_a
                               'st01_speed', 'st12_speed', 'st01_time', 'st12_
    return df
```

In [28]:

```
1 sessions = session_df(data)
```

```
HBox(children=(IntProgress(value=0, max=3000), HTML(value='')))
```

In [29]:

```
1 sessions.head()
```

Out[29]:

	session	total_points	st0_points	st1_points	st2_points	speed	st0_speed	st1_speed	st2_
0	0	115	39	26	50	3.911848	2.240553	1.150516	6.6
1	1	105	46	24	35	4.534931	4.271744	2.100467	6.5
2	2	72	17	13	42	4.994178	6.188842	1.225115	5.6
3	3	178	50	78	50	4.446038	6.626549	0.451911	8.4
4	4	179	50	97	32	1.198554	2.465206	0.664298	0.8

5 rows × 25 columns

In [30]:

```
1 sessions.shape
```

Out[30]:

```
(3000, 25)
```

Размерность получилась не очень большая, поэтому PCA, t-SNE и UMAP должны здесь хорошо работать (при большой размерности, t-SNE, например, плох).

In [31]:

```
1 pca = PCA(n_components=2)
2
3 principalComponents = pca.fit_transform(np.array(sessions.fillna(0.)))
4 principalDf = pd.DataFrame(data = principalComponents,
5                             columns = ['principal_component_1',
6                                        'principal_component_2'])
```

In [32]:

```
plt.figure(figsize=(10, 6))
plt.title('PCA', fontsize=14)
plt.scatter(principalDf.principal_component_1.values,
            principalDf.principal_component_2.values,
            alpha=0.4)
plt.show()
```

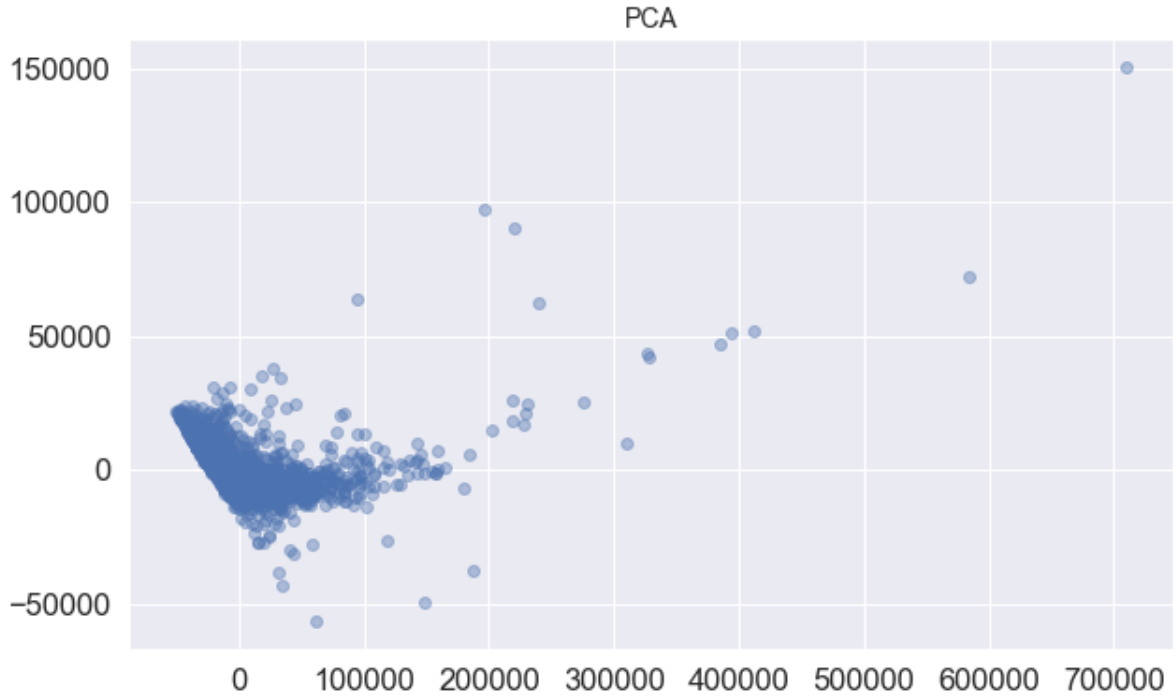

In [33]:

```
%%time

tsne = TSNE(n_components=2).fit_transform(np.array(sessions.fillna(0.)))
```

```
Wall time: 15.6 s
```

In [34]:

```
plt.figure(figsize=(10, 6))
plt.scatter(tsne[:, 0], tsne[:, 1],
            alpha=0.5)
plt.title('TSNE', fontsize=14)
plt.show()
```

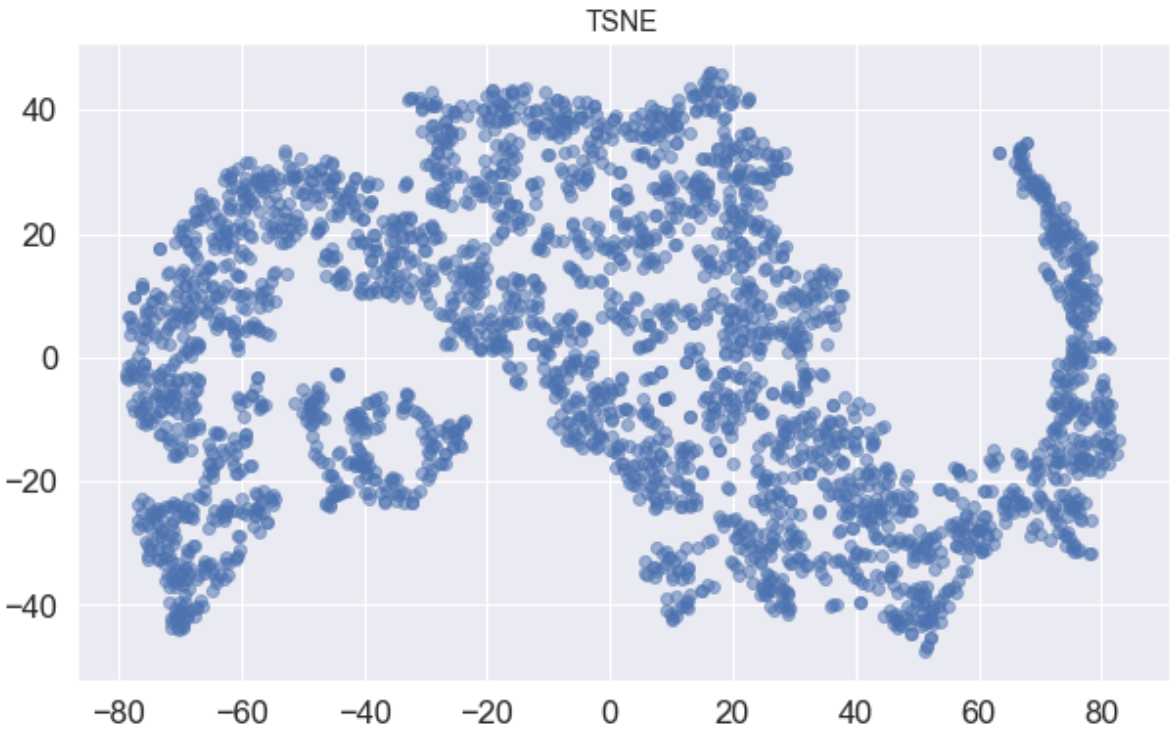

In [35]:

```
%%time

umap = UMAP(n_components=2,
            n_neighbors=15).fit_transform(np.array(sessions.fillna(0.)))
```

```
Wall time: 8.73 s
```

In [36]:

```
plt.figure(figsize=(10, 6))
plt.scatter(umap[:, 0], umap[:, 1],
            alpha=0.5)
plt.title('UMAP', fontsize=14)
plt.show()
```

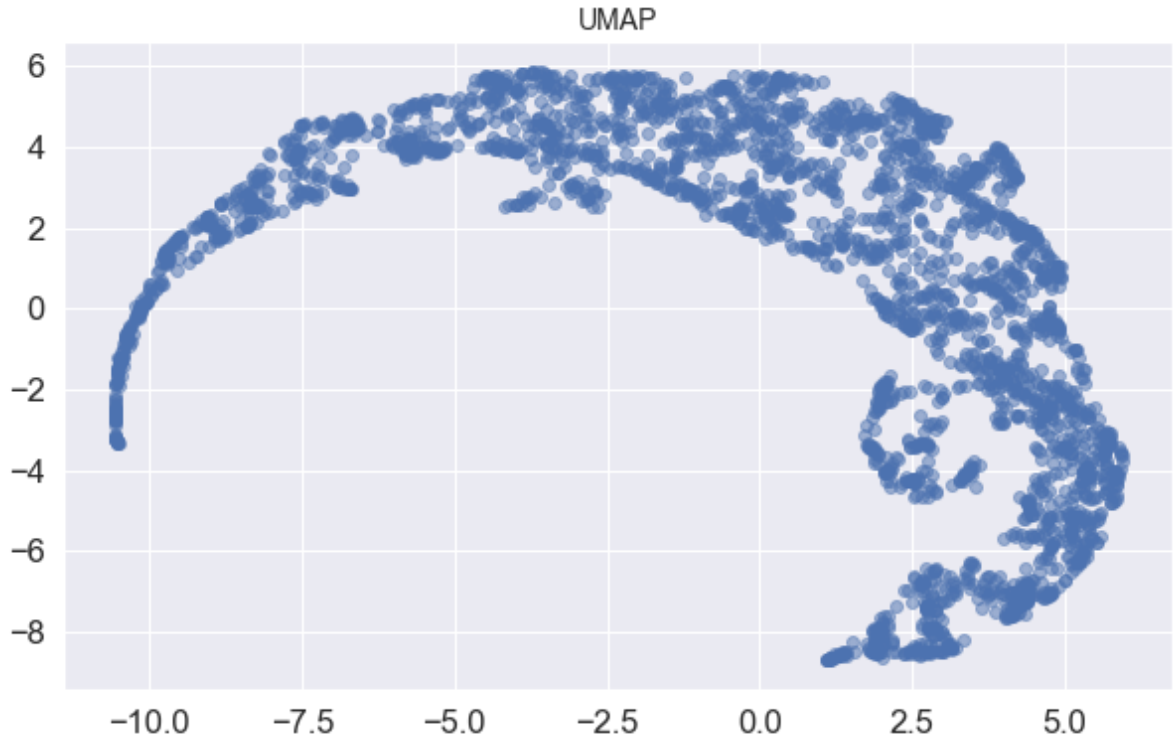

Результаты: PCA показал один кластер и выбросы. t-SNE и UMAP тоже отображают почти все сессии в одном кластере, но можно заметить небольшие "кучки" чуть отделенных от этого кластера сессий.

Глава 3. Метрика

1. Описание

Идейно:

Итак, поездки можно разделить на два типа:

1) Водитель вовремя включил статус 2.

2) Водитель опоздал с включением статуса 2. Тогда в статусе 1 есть набор точек, соответствующий "ожиданию" пассажира.

При этом случай (1) встречается гораздо чаще случая (2). Тогда логично в качестве метрики взять расстояние до первой (хронологически) точки со статусом 2 и применить некоторую регуляризацию: штрафовать метрику, если предсказанная точка слишком далеко от кластера "ожидания".

Формально:

Пусть к точкам со статусом 1 сессии с номером i применили кластеризацию на 3 кластера.

Пусть a_i - последняя по времени точка среднего кластера (кластера ожидания).

Пусть b_i - первая точка со статусом 2 в сессии.

Пусть ans_i - предсказанная точка посадки пассажира для данной сессии.

Тогда возьмем в качестве метрики:

$$f(a_i, b_i, ans_i) = \rho(ans_i, b_i) + \alpha\rho(ans_i, a_i)$$

Где α - некоторый параметр регуляризации, ρ - евклидово расстояние.

Тогда оценка качества предсказаний для многих сессий:

$$F(a, b, ans) = \frac{1}{N}\sum_{i=1}^{N} f(a_i, b_i, ans_i)$$

2. Имплементация

Создадим словарь для сессий: {номер сессии: [последняя точка в кластере ожидания, первая точка со статусом 2]}

In [44]:

```
eval_dict = {}

first_st2 = first_status_2(data)
for key, cluster_pred in zip(first_st2, predictions):
    cluster_point = (cluster_pred[1], cluster_pred[2])
    first2_point = first_st2[key]
    eval_dict[key] = [first2_point, cluster_point]
```

```
HBox(children=(IntProgress(value=0, max=3000), HTML(value='')))
```

In [48]:

```
eval_df = pd.DataFrame.from_dict(eval_dict, orient='index',
                                 columns=['cluster_pred', 'first_status2'])
```

In [49]:

```
1 eval_df.head()
```

Out[49]:

	cluster_pred	first_status2
0	(537.3231537026003, 73.614186697968)	(510.01726854950516, 93.06670560779078)
1	(467.8795440394896, 1009.9926489507196)	(535.7568380773753, 1020.0859420321573)
2	(-698.0440558086012, -39.04076617575709)	(-705.1528376654356, -71.80970340073668)
3	(-140.0357842608851, 2103.199405836623)	(-157.7600129313474, 2078.231321268458)
4	(-1033.5182993279884, -107.76234118736177)	(-892.8976919687669, -289.7585470426346)

Пусть preds - словарь предсказаний вида {номер сессии: точка посадки}

In [52]:

```
1  def dist(point1, point2):
2      return np.sqrt((point1[0] - point2[0])**2 + \
3                     (point1[1] - point2[1])**2)
4
5  def MyMetric(eval_dict, preds, alpha=0.1):
6      copy_eval = eval_df.copy()
7      metrics = []
8      for key in eval_dict:
9          a = eval_dict[key][0]
10         b = eval_dict[key][1]
11         metrics.append(alpha*dist(a, preds[key]) + \
12                        dist(b, preds[key]))
13
14     return metrics
```

3. Метрика для существуюших решений

3.1) Последняя точка со статусом 2

In [95]:

```
1 preds = first_status_2(data)
2 metrics = MyMetric(eval_dict, preds)
3
4 print(f'Значение метрики: {np.mean(metrics)}')
```

```
HBox(children=(IntProgress(value=0, max=3000), HTML(value='')))
```

```
Значение метрики: 30.471034867592156
```

In [96]:

```
def plot_metrics(metrics):
    plt.figure(figsize=(10, 4))

    plt.subplot(121)
    plt.title('Гистограмма значений метрики')
    plt.hist(metrics, bins=10)

    plt.subplot(122)
    plt.title('Boxplot значений метрики')
    sns.boxplot(metrics)

    plt.show()
```

In [97]:

```
plot_metrics(metrics)
```

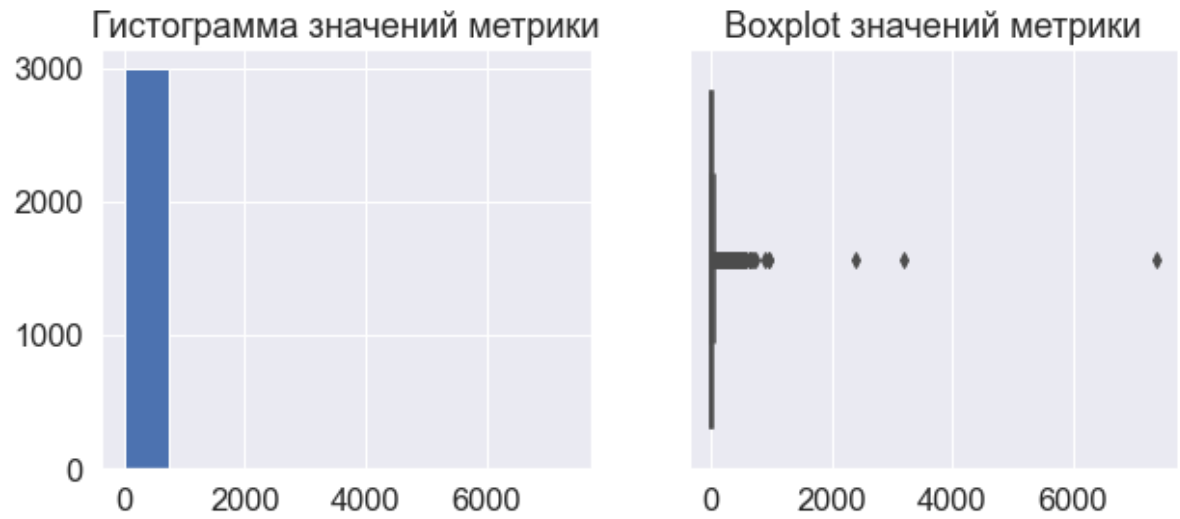

Как видим, получается очень много выбросов, посмотри на распределение метрики без них

In [98]:

```
q = np.quantile(metrics, q=0.95)
metrics = np.array(metrics)
metrics = metrics[np.where(metrics < q)[0]]
print(f'Значение после удаления выборосов: {np.mean(metrics)}')
```

```
Значение после удаления выборосов: 13.14584942756251
```

In [100]:

```
1 plot_metrics(metrics)
```

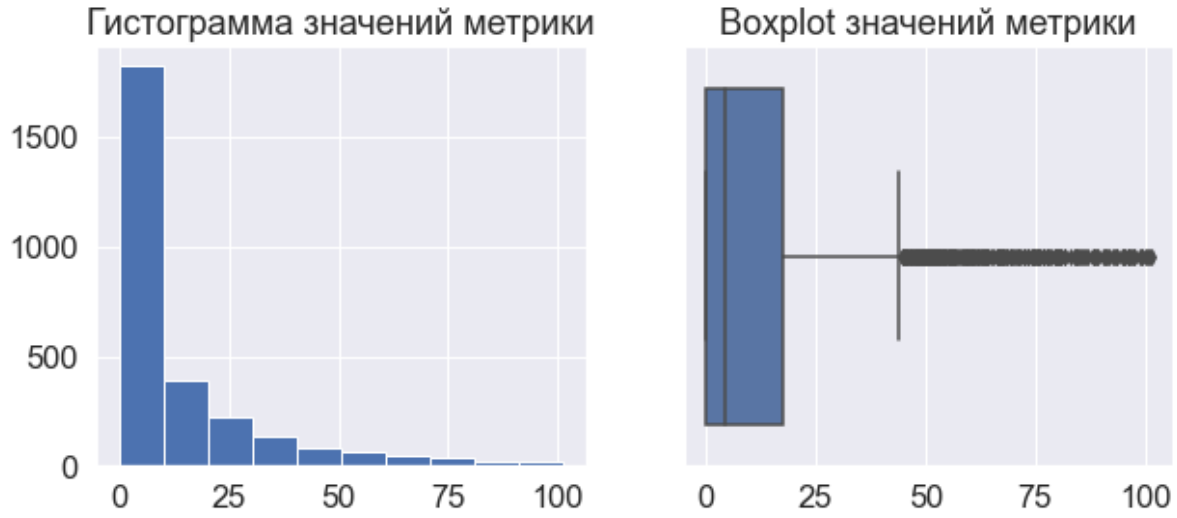

3.2) середина отрезка между точками со статусами 1 и 2

In [101]:

```
1 preds = middle_1_2(data)
2 metrics = MyMetric(eval_dict, preds)
3
4 print(f'Значение метрики: {np.mean(metrics)}')
```

```
HBox(children=(IntProgress(value=0, max=3000), HTML(value='')))
```

Значение метрики: 26.96261184315724

In [102]:

```
1 plot_metrics(metrics)
```

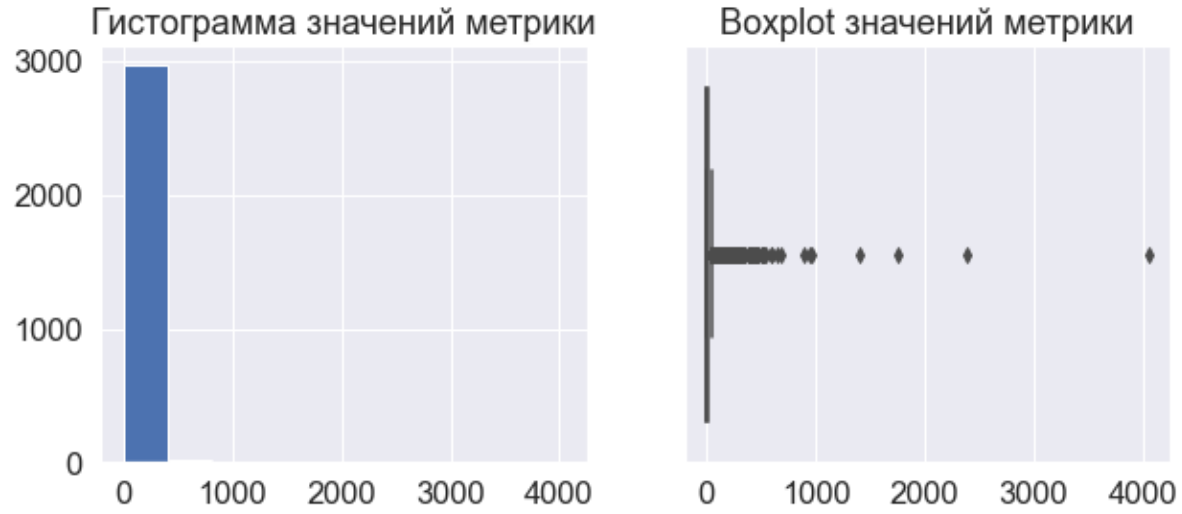

Снова много выбросов.

In [103]:

```
q = np.quantile(metrics, q=0.95)
metrics = np.array(metrics)
metrics = metrics[np.where(metrics < q)[0]]
print(f'Значение после удаления выборосов: {np.mean(metrics)}')

plot_metrics(metrics)
```

```
Значение после удаления выборосов: 12.018711285407644
```

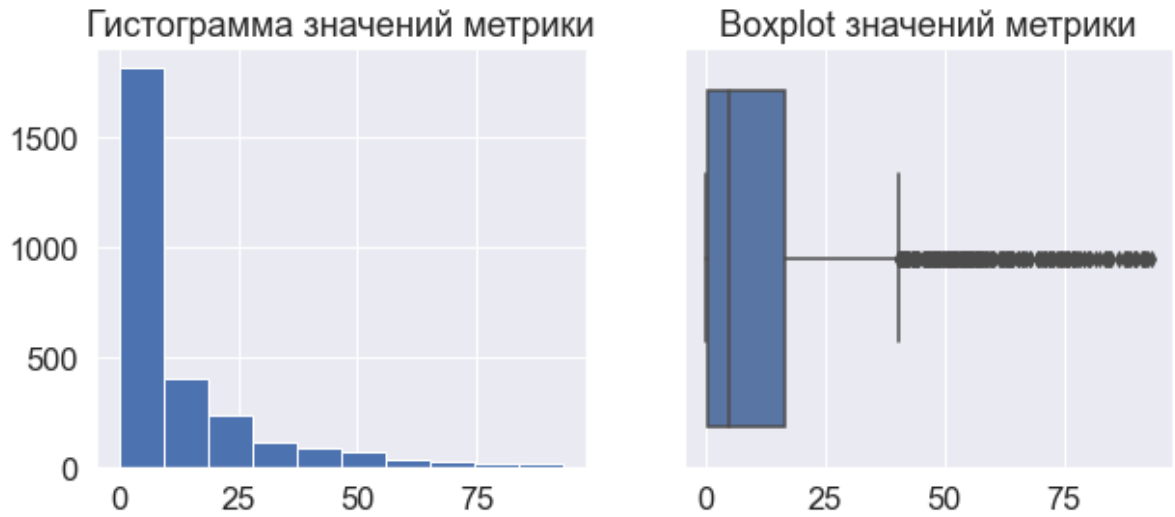

Результат: значение получилось меньше, чем если всегда брать точку со статусом 2.

3.3) статус 1, если статус 2 далеко, иначе статус 2

In [104]:

```
preds = distance_1_2(data)
metrics = MyMetric(eval_dict, preds)

print(f'Значение метрики: {np.mean(metrics)}')
```

```
HBox(children=(IntProgress(value=0, max=3000), HTML(value='')))

Значение метрики: 25.131300844831305
```

In [105]:

```
1 plot_metrics(metrics)
```

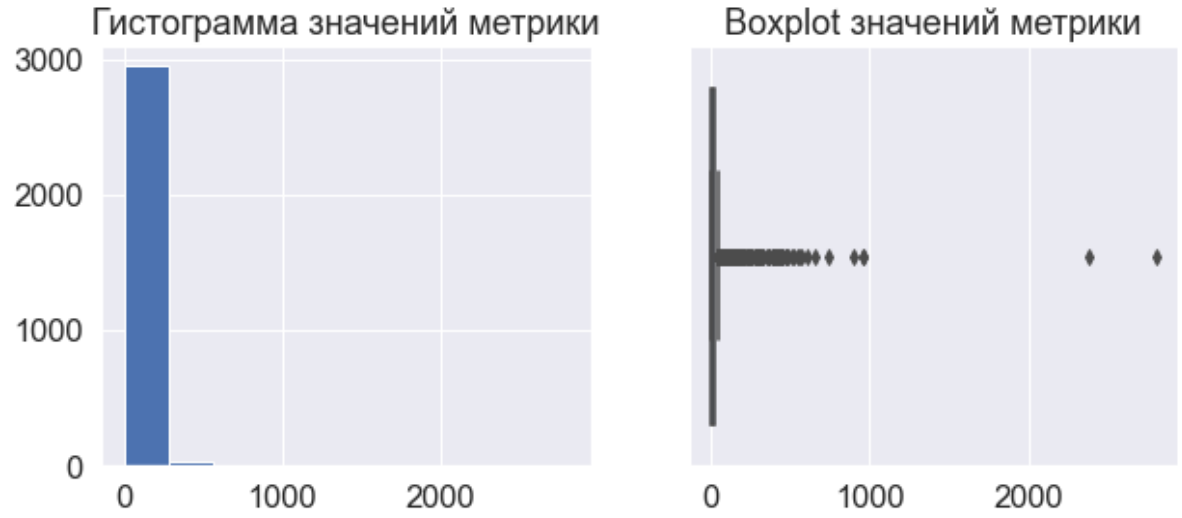

In [106]:

```
1 q = np.quantile(metrics, q=0.95)
2 metrics = np.array(metrics)
3 metrics = metrics[np.where(metrics < q)[0]]
4 print(f'Значение после удаления выборосов: {np.mean(metrics)}')
5
6 plot_metrics(metrics)
```

Значение после удаления выборосов: 11.84069061020883

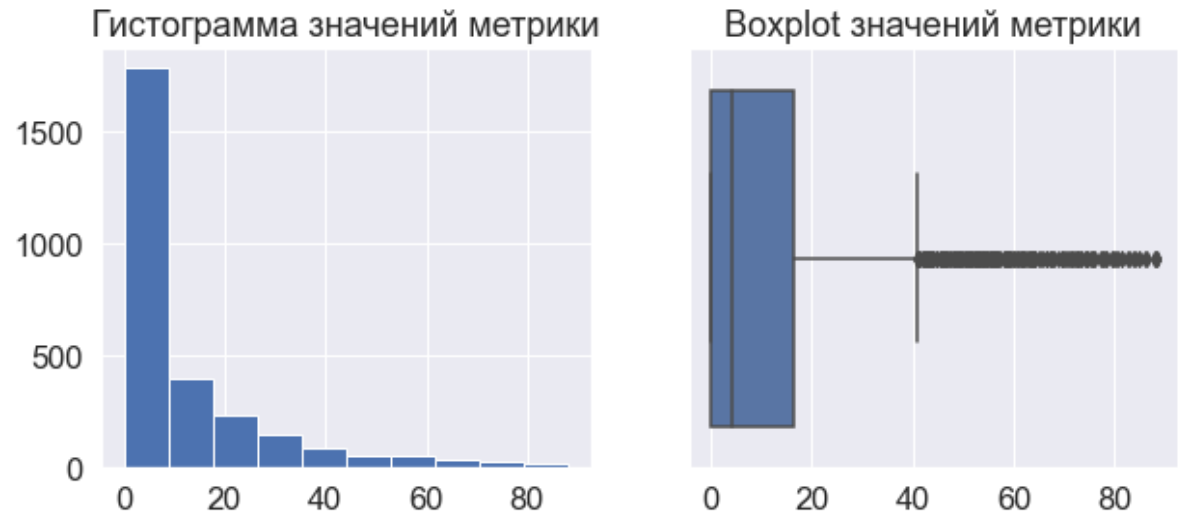

Результат: Для данного решения получилось много выбросов, но после их удаления решение выдало лучшее значение метрики, чем два других рассмотренных ранее.

3.4) последняя точка в кластере ожидания, если расстояние между точками этого кластера меньше некоторого порога, иначе первая точка со статусом 2.

In [119]:

```
preds = {}
for pred in valid_predictions:
    preds[int(pred[0])] = (pred[1], pred[2])

first2 = first_status_2(data)

for key in first2:
    if key not in preds:
        preds[key] = first2[key]

metrics = MyMetric(eval_dict, preds)

print(f'Значение метрики: {np.mean(metrics)}')
```

```
HBox(children=(IntProgress(value=0, max=3000), HTML(value='')))
```

Значение метрики: 8.03746068399398

In [120]:

```
plot_metrics(metrics)
```

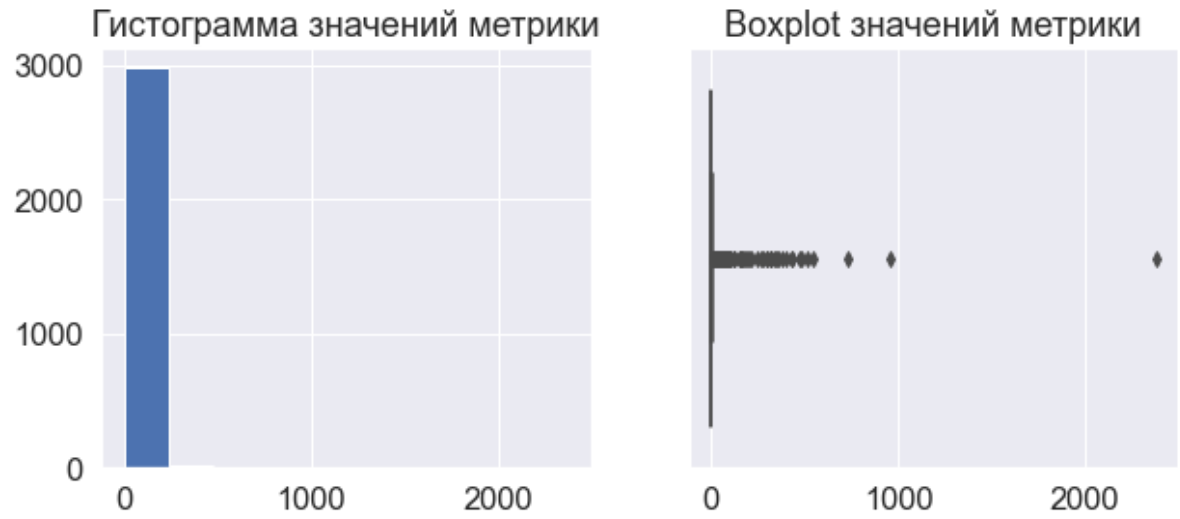

In [121]:

```
q = np.quantile(metrics, q=0.95)
metrics = np.array(metrics)
metrics = metrics[np.where(metrics < q)[0]]
print(f'Значение после удаления выборосов: {np.mean(metrics)}')

plot_metrics(metrics)
```

```
Значение после удаления выборосов: 1.85596380716079
```

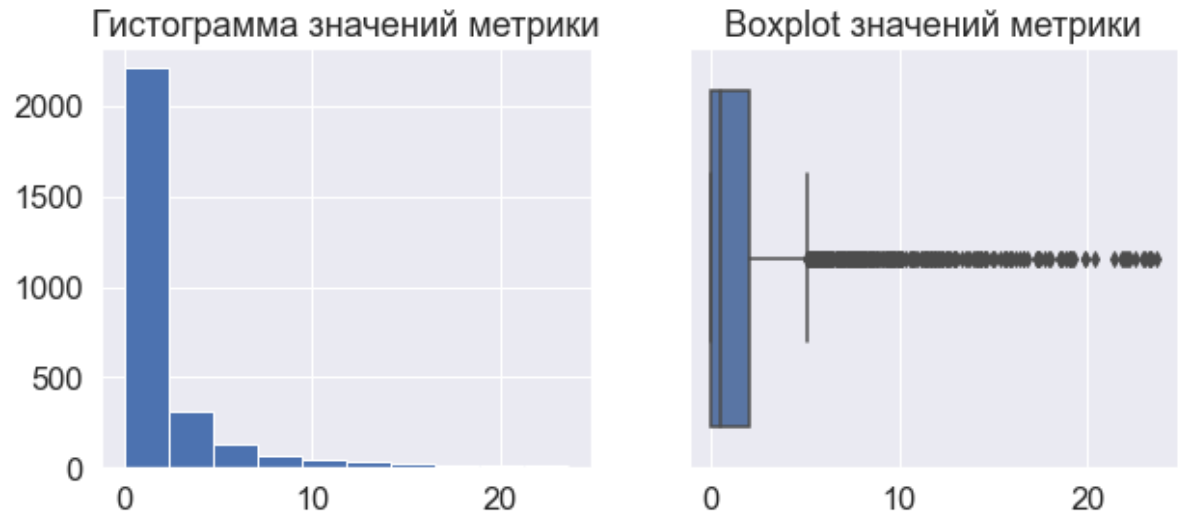

Результат: это решение оказалось наилучшим

4. Параметр регуляризации

Возьмем наилучшее решение, посмотрим как значение метрики будет меняться в зависимости от регуляризации

In [124]:

```
alphas = np.linspace(0.01, 1., 1000)

metrics = []
for alpha in alphas:
    metrics.append(np.mean(MyMetric(eval_dict, preds, alpha=alpha)))
```

In [126]:

```
plt.figure(figsize=(12, 6))
plt.title('Метрика в зависимости от регуляризации')
plt.plot(alphas, metrics)
plt.xlabel('alpha')
plt.ylabel('MyMetric')
plt.show()
```

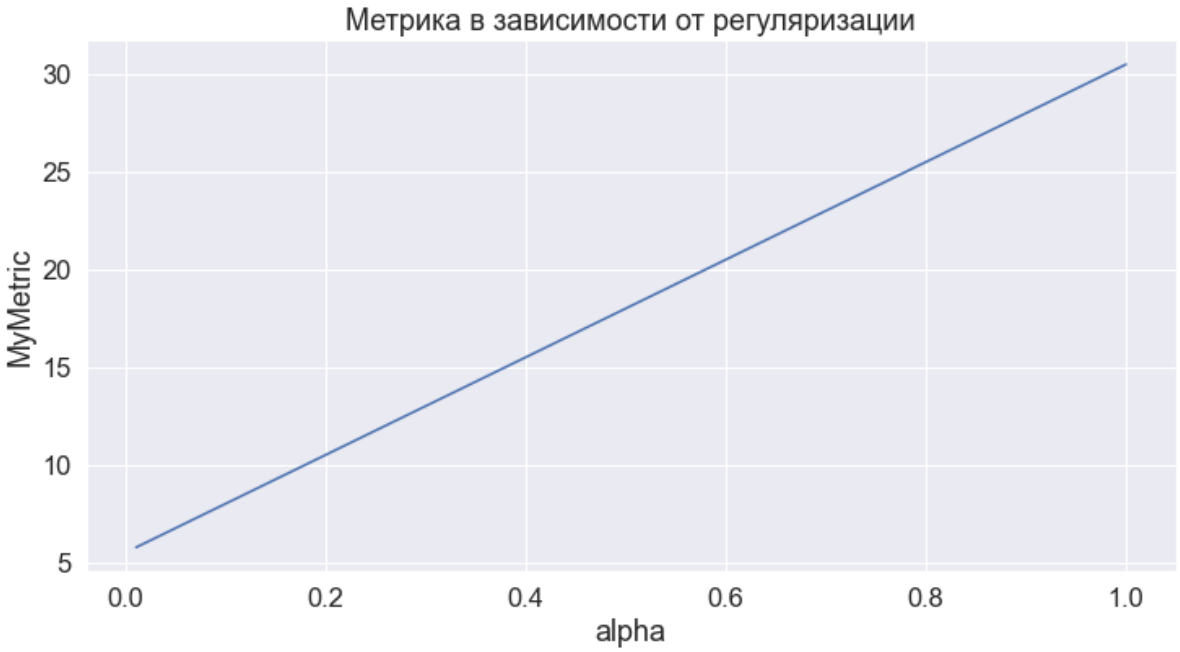

Результат: так как мы в большинстве случае предсказываем последнюю точку из кластера ожидания, то с ростом штрафа за отдаление от этого кластера растет и значение метрики.